

Proyecto final dados no estructurados Valentino Virlan

Introducción

En los últimos años, y especialmente de manera muy evidente en el contexto contemporáneo, las crisis geopolíticas han ido acompañadas por una ampliación significativa del tiempo y del espacio que los medios dedican a su cobertura. Este aumento no se refiere exclusivamente a la naturaleza cuantitativa, sino que se refiere en primer lugar a las modalidades a través de las cuales los acontecimientos son narrados, contextualizados e insertados en marcos interpretativos más amplios. La resonancia mediática tiende a mantener una gran continuidad narrativa en el tiempo, produciendo resultados que conducen a redefinir la percepción de la relevancia de los eventos en el debate público. En segundo lugar, en el contexto informativo contemporáneo, la información asume un papel absoluto de estrategia: por qué hablar de una crisis, seleccionar determinados temas y decidir a cuáles de ellos atribuir visibilidad puede ayudar a orientar el contexto informativo en el que se interpretan los acontecimientos. Finalmente, la integración de los medios tradicionales y plataformas digitales ha acentuado terriblemente la dimensión global de la información, haciendo posible que eventos locales adquieran rápidamente una resonancia global, en cualquier plataforma, terminando en el centro del debate público. En este marco, la atención mediática, entendida como capacidad de los medios para seleccionar, tematizar y enfatizar eventos específicos, representa un concepto clave para comprender cómo las crisis geopolíticas se organizan y narran en el espacio informativo internacional. La literatura sugiere que la agenda informativa global no sigue una evolución lineal, sino que está llena de discontinuidades y puntos de inflexión desencadenados por acontecimientos críticos repentinos a veces, capaces de catalizar y reorientar en un instante la atención de los medios.

Estas dinámicas son coherentes con la idea de la atención no lineal (Baumgartner & Jones, 1993) y con los principios fundacionales del agenda-setting (McCombs & Shaw, 1972), según los cuales los acontecimientos salientes pueden redefinir temporalmente las prioridades informativas. El análisis de estas dinámicas se enfrenta a un desafío metodológico muy importante: la mayor parte de la información producida por los medios es de naturaleza textual no estructurada, difícil de interpretar en contraste con indicadores cuantitativos. Los datos no estructurados como los textos periodísticos en sus contenidos contienen información que va más allá de la frecuencia de las noticias, de hecho tienen un lenguaje característico según la región de procedencia, tienen temas específicos que recurren especialmente seleccionados por un escritor, Un proceso editorial o incluso convenciones periodísticas que enfatizan ciertos aspectos de los eventos descritos, a menudo recurriendo a estrategias, elecciones lingüísticas y retóricas para mantener al lector enganchado. Extraer y analizar sistemáticamente estas señales es una tarea que requiere absolutamente una herramienta computacional, capaz de operar sobre grandes masas de datos de manera coherente y replicable por otros. En esta visión se enlaza el siguiente trabajo, que utiliza datos abiertos del proyecto GDELT para analizar la cobertura mediática de tres crisis geopolíticas recientes: la guerra en Ucrania (iniciada en febrero de 2022) una invasión a gran escala que trajo la guerra al corazón de Europa, causando cientos de miles de víctimas, una crisis migratoria y reconfigurando radicalmente los equilibrios entre las superpotencias mundiales, pero sobre todo entre la OTAN y Rusia.

La segunda crisis analizada es la escalada del conflicto en Gaza (en octubre de 2023), surgida después de la vasta y compleja ofensiva militar lanzada el 7 de octubre de 2023 contra Israel por Hamas, que ha dado lugar a una crisis humanitaria y a una intensificación del conflicto sin precedentes en Oriente Medio, además de un enorme impacto mediático global que ve la escena internacional desplegada de

manera fuertemente polarizada. Y como última crisis analizada elegí la político-institucional en Venezuela (2024-2025), que ve un contexto de inestabilidad prolongada que ha visto un nuevo pico después de las disputadas elecciones presidenciales de julio de 2024, llevando a una ola de protestas, Sanciones internacionales y un intenso debate sobre la legitimidad democrática en el cuadrante latinoamericano, todo ello culminando con los acontecimientos vinculados a la captura y destitución de Nicolás Maduro. La selección de estos tres casos permite comparar el modo de cobertura mediática relativa a eventos diferentes por naturaleza, éxitos en zonas geográficas diferentes y con duraciones, y posteriormente seleccionados períodos diferentes, Pero los tres tienen en común una gran centralidad en el debate público internacional. El proyecto GDELT (Global Database of Events, Language, and Tone) no es un simple archivo de artículos diarios extraídos de las páginas web de casi todos los países y en más de 100 idiomas; GDELT extrae personas, organizaciones, temas y señales léxicas que mueven la sociedad global.

El proyecto ofrece así una plataforma de datos abiertos que permite analizar computacionalmente lo que sucede en el mundo, segundo por segundo. Los datos proporcionados describen metadatos de fuentes, volúmenes de menciones de artículos, indicadores de atención y señales semánticas extraídas a través de una canalización compleja, utilizando algoritmos de procesamiento del lenguaje natural para transformar textos no estructurados en datos codificados, cada 15 minutos a escala mundial, lo que permite observar cómo se produce y distribuye la información en el tiempo. Al ser señales automáticas, no representan medidas directas de la percepción real, de posibles opiniones o emociones de los lectores; por el contrario, son aproximaciones léxicas y cuantitativas útiles para describir y comprender cómo se mueve la información en su conjunto. Por lo tanto, el objetivo final de este trabajo no es establecer cuáles son las relaciones causales entre los eventos geopolíticos y qué reacciones tiene la opinión pública, ni inferir sobre estados emocionales individuales, pero proporcionar una lectura descriptiva y comparativa de las dinámicas de la atención mediática y del marco conceptual que surgen de la cobertura de la información global. Desde el punto de vista metodológico, el proyecto se basa en una canalización de análisis estructurada que integra los datos abiertos procedentes de GDELT con técnicas de análisis de texto y de red. Los datos se recopilan a partir de los archivos oficiales (GDELT Translation GKG y Translation Mentions) sobre el uso del GDELT, y luego se seleccionan dentro de ventanas temporales específicas para cada evento, para garantizar la coherencia comparativa y centrarse mejor en las perturbaciones informativas iniciales.

Posteriormente los datos brutos se someten a un preprocessing que incluye también la verificación de la estructura de las variables, el mapping de las columnas, la extracción de los metadatos relevantes (por ejemplo dominios, fechas, títulos, señales semánticas), la construcción de un panel evento-día-dominio e integración de los indicadores de atención mediática basados en el número de menciones. Con este enfoque se puede medir no solo el significado de los datos, sino también su impacto volumétrico. El análisis del contenido textual se divide en varios niveles diferentes. Primero, los títulos de los artículos se extrajeron directamente de los metadatos GDELT y luego se analizaron mediante métodos NLP, incluyendo tokenización, análisis de frecuencia, medidas de distintividad léxica (TD-IDF) y comparación entre períodos de alta y baja atención mediática. En paralelo, utilizamos los flujos GCAM como representaciones semánticas para seguir cómo cambia la narración lingüística de los hechos. La integración con los parámetros de atención nos permite detectar si hay desplazamientos comunes y dinámicos en el tiempo entre la cobertura mediática y el interés del público, entender si la manera en que hablan los medios influye en lo que las personas buscan o ven. En segundo lugar, el proyecto también integra en su segunda parte un análisis basado en la web scraping dirigido a un subconjunto seleccionado de artículos periodísticos con alta atención mediática,

identificados utilizando como base el volumen de las menciones, para poder comparar el lenguaje de los títulos con el desarrollado posteriormente dentro de los artículos.

Este paso permite comparar la esencia comunicativa del título, que es una representación condensada, con el desarrollo del artículo (narración extendida), distinguiendo el hecho reportado del corte interpretativo adoptado por el autor. Por último, el análisis concluye con la exploración de las relaciones entre los diferentes medios: construyendo varias redes de cobertura (periódicos, sitios web, TV) de los eventos. Examinando estas redes a través de las medidas métricas de centralidad es posible mapear la estructura del ecosistema informativo para identificar qué fuentes son más influyentes durante una crisis. Por lo tanto, en general las técnicas de NLP, el análisis de señales GCAM y los instrumentos de análisis de redes se utilizan en clave exploratoria y descriptiva. Los resultados no se interpretan como soluciones aproximadas de los fenómenos mediáticos. El análisis, por el contrario, se limita a describir las dinámicas de visibilidad y las tendencias léxicas surgidas, evitando inferencias directas sobre el verdadero sentimiento o sobre las relaciones de causa-efecto entre los eventos y sus narraciones. En resumen, mi análisis se inserta en un contexto de investigación que analiza el papel de los medios y flujos de información en la representación de las crisis geopolíticas, mostrando cómo el uso e integración de datos no estructurados. Los indicadores de atención y análisis relacionales pueden apoyar actividades de seguimiento informativo y análisis exploratorio. Mediante la comparación de tres crisis diferentes, el proyecto tiene como objetivo poner de relieve las similitudes y diferencias en los patrones de atención, los contextos lingüísticos y las redes de información que surgen de la cobertura global de los medios de comunicación, contribuyendo a la comprensión de la dinámica de la información internacional.

Marco Teórico

La base teórica del análisis de la cobertura mediática se encuentra en la función agenda-setting, definida por McCombs y Shaw (1972). Constituye la base para comprender cómo los medios de comunicación no solo sirven para transmitir información, sino que también ejercen una influencia muy importante en la jerarquía de importancia asignada a los diferentes temas globales. Un evento geopolítico se hace importante cuando es posible observar un incremento en la densidad y persistencia de su cobertura en las fuentes periodísticas. Fuentes que actúan como un filtro capaz de señalar qué cuestiones son centrales y cuáles requieren mayor atención pública. En un contexto como los datos masivos de hoy, estudiar el volumen de noticias ayuda a entender qué tan importante es una crisis. Sin embargo, la prominencia mediática de un evento no se distribuye uniformemente en el tiempo, pero sigue una dinámica caracterizada por fuertes discontinuidades.

La distribución de la atención mediática no es constante en el tiempo y recta, pero está descrita por la teoría del equilibrio punteado de Baumgartner y Jones (1993). Este modelo sugiere que los sistemas de información se caracterizan por momentos estables durante largos períodos, que son interrumpidos por cambios bruscos, o "punteados", en respuesta a nuevos impulsos o choques que cambian todo. Estas dinámicas implican que la atención mediática hacia una crisis no es en absoluto lineal: un evento crítico es capaz de saturar en muy poco tiempo la agenda, desplazando el interés de temas anteriormente relevantes al nuevo centro del conflicto. Por lo tanto, la configuración de la atención no es más que un recurso escaso que se centra en unos pocos eventos de gran magnitud. Estas dinámicas son particularmente evidentes en el caso de las crisis geopolíticas, que son ejemplos de eventos capaces de interrumpir la comunicación ordinaria. Las crisis geopolíticas pueden ser interpretadas como eventos informativos repentinos o "focusing events" que interrumpen la comunicación ordinaria

y los procesos políticos normales, la rutina normal. Según Cavari y Edfrat (2025), una crisis es un evento de ruptura donde las instituciones o procedimientos estables no logran resolver los conflictos, generando así un sentido de amenaza urgente a los valores o a las bases estructurales de una comunidad. Estos choques reorientan las prioridades de comunicación, lo que lleva a una reducción de la diversidad de la agenda general en favor de un enfoque centrado en el tema del conflicto. Sobre todo las crisis vinculadas a la seguridad externa producen una solidificación de la agenda, donde la prioridad se convierte en la función central del estado, como la defensa y las relaciones internacionales. Además de la cantidad de atención generada, las crisis también difieren en cómo se narran entre sí e interpretan en el espacio mediático.

Además del volumen de cobertura, la naturaleza de la información está determinada por el contexto informativo, entendido por Entman (1993) como la selección de algunos aspectos de una realidad percibida para hacerlos más relevantes. En un enfoque de análisis de datos no estructurados, el contexto informativo no se investiga como un estado psicológico, sino como la presencia o ausencia de señales lingüísticas específicas y palabras que definen el problema. A través de diccionarios léxicos automáticos, es posible encontrar patrones recurrentes en las expresiones que caracterizan una crisis. En este cuadro, el sentimiento o tono se utiliza exclusivamente como proxy léxico automático. No es más que la media calculada algorítmicamente de la positividad o negatividad de los términos presentes en los textos, que ayuda a proporcionar una descripción más cuantitativa de la dirección del lenguaje utilizado por los medios sin implicar inferencias sobre los estados mentales de los productores o lectores de las noticias. El análisis empírico de estas dinámicas requiere instrumentos capaces de observar simultáneamente los volúmenes de información y las señales lingüísticas a gran escala. La integración de todos los conceptos teóricos enumerados anteriormente es posible gracias a la aparición de sistemas basados en noticias que monitorean a gran escala como GDELT (Global Database of Events, Language, and Tone), desarrollado por Leetaru y Schrodtt (2013). GDELT monitoriza decenas de miles de fuentes periodísticas globales en tiempo real, extrayendo metadatos sobre entidades, temas y "event data" mediante técnicas de Natural Language Processing (NLP).

GDELT incluye varias secciones dedicadas al análisis de la información internacional. En particular, el Global Knowledge Graph (GKG) permite cartografiar temas, entidades y señales lingüísticas a través de diccionarios léxicos predefinidos, mientras que el conjunto de datos Mentions permite medir la intensidad de la cobertura mediática asociada a los artículos. El uso simultáneo de estos dos componentes hace posible el análisis comparativo y exploratorio de crisis geopolíticas, vinculando la variabilidad de la atención mediática y del lenguaje periodístico con las dinámicas temporales y la distribución entre diferentes fuentes informativas. Este enfoque permite el análisis de las crisis geopolíticas como fenómenos informativos agregados, ofreciendo la base para el estudio de las dinámicas de atención, los patrones lingüísticos y las relaciones entre actores mediáticos, preparando la aplicación de métodos de análisis de redes y series históricas.

Datos y metodología

Datos

Como ya se ha dicho, los datos de este trabajo provienen del proyecto GDELT. En coherencia con el objetivo de estudiar las dinámicas de la atención mediática y del contexto informativo, el análisis utiliza solo dos de los diversos componentes de la base de datos GDELT 2.1: el Global Knowledge Graph (GKG), que proporciona metadatos semánticos a nivel de documento, en la práctica incluye información sobre temas, señales lingüísticas avanzadas, Global Content Analysis Measures

(GCAM), tono lexical, título del artículo y también el dominio de la fuente, y el dataset Mentions que permite medir la resonancia de una noticia en el espacio público, a través del recuento de citas y republicaciones de artículos por otras fuentes. La integración de estos componentes nos permite correlacionar la caracterización semántica de los eventos con su alcance volumétrico, devolviéndonos una imagen con calidad de narración y resonancia efectiva conjuntas en el ecosistema informativo. Para ambos componentes del proyecto se utilizaron únicamente los archivos de traducción (Translation GKG y Translation Mentions), para incluir sistemáticamente contenidos originalmente publicados en idiomas distintos del inglés y reducir los posibles sesgos lingüísticos en la comparación internacional, evitando así una fuente exclusiva anglosajona o predominantemente estadounidense, que haría reflejar las prioridades editoriales y el interés informativo específico de un solo contexto mediático, comprometiendo el objetivo de representación global de la cobertura. Los datos se han descargado del repositorio oficial de GDELT utilizando el masterfilelist, que enumera exhaustivamente los archivos disponibles con referencia temporal. Para cada día incluido en los intervalos de tiempo seleccionados para este proyecto, se seleccionó un archivo de Translation GKG y un archivo de Translation Mentions. Los archivos en bruto fueron luego sometidos a una fase de preprocessing que se refería principalmente a verificar la estructura de las variables, la extracción de los metadatos relevantes y la agregación de las menciones a nivel evento-día-dominio. La integración de GKG y Mentions permitió construir finalmente un panel analítico evento-día-dominio, que constituye la base común para todos los análisis posteriores realizados.

Metodología

En una primera fase para el proyecto he definido la estructura básica de cómo tenía intención de proceder, creando un directorio exclusivamente para los datos y una subcarpeta específica para los archivos crudos (raw), dentro del cual se han guardado todos los datasets descargados. Esta organización es óptima y permite mantener separados los datos originales para las sucesivas versiones preprocesadas, facilitando también considerablemente el trabajo de trazabilidad, pero sobre todo la reproducibilidad del análisis. A continuación definí las ventanas de tiempo de análisis para cada evento de estudio. Esta elección está motivada principalmente por consideraciones relacionadas con la estructura temporal de los datos de GDELT. En particular, para los momentos y períodos más recientes los datasets pueden ser parciales o sujetos a revisiones sucesivas, por diversas razones de ingestión, Traducción y consolidación de las fuentes supervisadas. Además, la elección también está motivada por la sostenibilidad del cálculo para gestionar de manera eficiente el gran número de datos y garantizar la replicabilidad de todo el flujo de datos. En particular para la guerra en Ucrania se eligió la ventana entre el 24 de febrero 2022 y el 5 de marzo 2022, una ventana temporal que cubre la fase inicial de la invasión rusa de Ucrania, marcada por el ataque a gran escala y el primer avance hacia la capital Kiev. He considerado este período como el apogeo de la prominencia mediática global, caracterizado por las primeras fuertes reacciones internacionales como las múltiples sanciones contra Rusia, Desde el inicio de una oleada masiva de refugiados ucranianos hacia Europa y la drástica reconfiguración de la postura de defensa europea con una decisión de rearme, en práctica podríamos llamar a este período el Big Bang y los momentos posteriores.

Para la escalada en Gaza, la ventana que elegí es entre el 7 de octubre de 2023 y el 17 de octubre de 2023, es decir, el período entre el estallido de las hostilidades como nunca antes, por la repentina incursión armada de Hamás en el sur de Israel y la consiguiente respuesta militar a gran escala en la Franja de Gaza. Este período ha marcado la fase de máxima intensidad en los flujos informativos, en la reciente historia del conflicto, marcada también por un rapidísimo desplazamiento del foco mediático: del acontecimiento bélico inicial a la crisis humanitaria culminada con el incidente en el

hospital Al-Ahli, por lo tanto las razones de la elección del período son porque esto nos proporciona un caso de estudio ideal para el análisis de la polarización del encuadre y la velocidad de propagación de las noticias en contextos de crisis. Por último, para la crisis político-institucional en Venezuela, la ventana seleccionada es del 25 de diciembre de 2024 al 5 de enero de 2025 que analiza la fase culminante de la crisis, con el evento que culmina la intervención militar estadounidense, la Operación Absolute Resolve. Se definieron las ventanas a nivel diario y luego se implementaron directamente en el código como secuencias de fechas, que se utilizaron para filtrar los archivos GDELT que debían descargarse. El proceso de adquisición de datos se realizó desde el repositorio oficial del proyecto GDELT, utilizando la lista maestra, un archivo de índice público que enumera exhaustivamente todos los conjuntos de datos disponibles, especificando el tamaño, el hash de control y las direcciones URL de descarga. La lista maestra se descargó localmente, luego a partir de este índice creado, para cada evento y para cada día incluido en las ventanas temporales definidas, se seleccionaron los archivos GKG y Mentions correspondientes a esa fecha exacta. Por lo tanto, solo se ha adquirido un archivo de Translations GKG y Translations Mentions para cada día.

Debido a que GDELT hace disponibles varias instantáneas por día disponibles con una frecuencia muy alta, decidí limitar la captura a un solo archivo por tipo y día permitiendo mantener una unidad de tiempo coherente con mi análisis, para evitar también superposiciones informativas entre varias instantáneas y posibles duplicaciones. La descarga de los archivos se realizó con un ciclo iterativo en cada evento y en cada fecha en las ventanas. Luego, para cada archivo, creé un control de captura real para excluir archivos vacíos e incompletos; si el archivo no supera el control de calidad, se descartará automáticamente y no se incluirá en el conjunto de datos sin procesar. Los archivos válidos se han guardado en el directorio dedicado a los datos brutos (raw), he utilizado una convención de denominación (YYYYMDMDhhmmss) para asociar cada archivo al evento de referencia y a la fecha de publicación, facilitando así la trazabilidad y reproducibilidad. La segunda fase del proyecto se dedicó al procesamiento de los datos GDELT adquiridos y a la construcción de un conjunto de datos analíticos que esté estructurado, para constituir la base de todos los análisis posteriores. En esta fase tuve el objetivo de transformar los archivos brutos GKG y Mentions, caracterizados por una estructura compleja y semi-estructurada, en un conjunto coherente con variables que puedan ser interpretadas y agregadas a nivel evento-día-dominio. Primero definí los dos directorios de entrada y salida, para distinguir los archivos brutos de los procesados (procesados). Todas las salidas intermedias y finales de esta fase se han guardado en un directorio dedicado, para preservar la integridad y reproducibilidad.

Dado que los archivos GDELT descargados contienen la cobertura informativa global de cada día, he considerado necesario asociar cada observación al evento del estudio de referencia. Con este evento (Ucrania, Gaza o Venezuela) se dedujo en base al nombre del archivo de origen, dado por la convención explicada anteriormente. De esta manera pude mantener separados desde el principio los flujos de información relativos a los diferentes estudios de caso ya en el preprocessing. Antes de extraer las variables relevantes, realicé una comprobación de la estructura del archivo Translation GKG, cargando un archivo de muestra para identificar el número de columnas y el contenido de los distintos campos. La verificación confirmó la presencia de 27 columnas, consistente con la documentación oficial de GDELT. Luego quise construir un mapeo de las columnas GKG, para asociar a cada campo técnico una descripción explícita (marca de tiempo del documento, dominio de la fuente, URL, temas, personas, organizaciones, tono, señales GCAM, metadatos de página). La asignación se ha guardado como un archivo separado (gkg_column_map.csv) para documentar las opciones de preprocessing. Posteriormente procesé todos los archivos GKG de forma iterativa. Para

cada archivo, los datos se leyeron preservando la estructura original y cambiando el nombre de las columnas uniformemente. Luego extraje de cada archivo solo las variables relevantes para el análisis, incluyendo la marca de tiempo del documento, URL del artículo, dominio de la fuente, temas asociados al artículo, personas y organizaciones mencionadas, tono lexical agregado, señales semánticas avanzadas GCAM y metadatos de página, del cual se extrajo el título del artículo. La marca de tiempo se ha convertido en una variable de fecha a nivel diario, para mantener la coherencia con la unidad de tiempo del análisis.

He normalizado el dominio de la fuente extrayendo el dominio principal de la URL y convirtiéndolo en letras minúsculas. para evitar duplicaciones debido a cambios formales, por ejemplo presencia o ausencia de "www". El tono léxico se ha convertido en formato numérico a partir de la representación textual original, mientras que para la extracción de los títulos de los artículos se ha realizado a partir de los metadatos de página, utilizando un parsing basado en patrones textuales. De esta manera pude disponer de una información textual sintética directamente asociada a cada documento y posteriormente utilizada en los análisis NLP. Después comprobé también la cobertura de las señales GCAM, que estaban disponibles para todos los documentos analizados, sin valores nulos, confirmando así la idoneidad del uso de estas medidas para el análisis de framing semántico. En paralelo, también se procesaron los archivos Translation Mentions, una vez más leídos iterativamente, y con la extracción de timestamp, URL del artículo y evento de referencia. Una vez convertida la marca de tiempo en la variable de fecha diaria y el dominio normalizado, a partir de los datos de Mentions he construido un indicador de atención mediática agregando el número de citas a nivel evento-día-dominio. Esta agregación permite cuantificar, para cada fuente y en cada día, el número de veces que los contenidos publicados son tomados o citados por otras fuentes. El número de menciones por día representa una medida cuantitativa de la intensidad de la cobertura mediática asociada a cada fuente, constituyendo la base para el análisis de la atención a lo largo del tiempo. La última fase de la fase de procesamiento ha consistido en integrar los datos GKG y Mentions en un único panel analítico. La combinación de los dos conjuntos de datos se realizó utilizando como clave común el evento, la fecha y el dominio de la fuente.

Permitiendo asociar, para cada documento y para cada fuente, las características semánticas del contenido informativo para una medida de la atención mediática generada. Para evitar problemas si hay dominios presentes en GKG pero no en las menciones en un día determinado, entonces en ese caso se maneja con un número de menciones establecido a cero, evitando así perder observaciones relevantes. El resultado final de toda esta fase es un panel evento-día-dominio que simultáneamente dice contenido, tono, framing semántico e intensidad de la cobertura mediática. Los conjuntos de datos que creé y procesé al final (gdelt_gkg.csv, gdelt_mentions_daily.csv y gdelt_panel.csv), junto con el archivo de mapeo de las columnas iniciales, se guardaron en el directorio para los datos procesados y son la base para análisis posteriores de la atención de los medios, framing GCAM, NLP exploratorio y análisis de red, contenidos dentro de este proyecto. En esta fase del proyecto se llevó a cabo un análisis NLP exploratorio basado exclusivamente en los titulares de los artículos.

Esta elección que he tomado corresponde a una precisa motivación metodológica: el título no es más que una síntesis condensada del contenido informativo y es el principal dispositivo con el cual las redacciones seleccionan, enfatizan y enmarcan los eventos. Por eso he considerado que el análisis del lenguaje de los títulos permite observar directamente las estrategias de tematización y framing adoptadas en el contexto informativo global, evitando, como ventaja, la complejidad y la heterogeneidad semántica de los textos completos de los artículos. He realizado el análisis del conjunto de datos GKG procesado extrayendo los artículos de los metadatos de página asociados a

cada documento, utilizando como se mencionó anteriormente un análisis que contiene la información del HTML de la página (PAGE_TITLE). Solo se han mantenido para el análisis los títulos que estaban realmente presentes y no nulos, para garantizar la fiabilidad de los análisis textuales posteriores. Este procedimiento me ha permitido obtener un corpus de cuarenta mil títulos válidos, distribuidos en los tres eventos seleccionados para el estudio. Los títulos extraídos se han normalizado para reducir el ruido léxico y permitir la comparación del texto entre diferentes fuentes y contenidos. En particular, los convertí a minúsculas, eliminé las entidades HTML residuales, los caracteres no alfabéticos y los símbolos de puntuación, y eliminé los espacios múltiples.

Esta limpieza se ha hecho deliberadamente de manera conservadora sin aplicar ninguna lematización o stemming, aunque el objetivo de este proyecto no es reducir las palabras a formas canónicas, pero con este análisis NLP observar el uso efectivo del léxico en los títulos tal y como aparece en el espacio mediático. Los títulos normalizados se han transformado posteriormente en un formato adecuado para el análisis NLP mediante tokenización, desglosando el texto en palabras individuales (tokens). Para eliminar los términos poco informativos y puramente funcionales, se han excluido los tokens con una longitud inferior a 4 caracteres y las palabras de parada del idioma inglés. El resultado que obtuve es un corpus léxico estructurado, donde cada token tiene una asociación directa al evento de referencia, a la fecha de publicación y al dominio de la fuente. Para identificar los términos más recurrentes en los datos, hice un primer análisis descriptivo calculando las frecuencias globales de las palabras en los títulos. De esta manera he observado qué conceptos dominan la cobertura mediática agregada y no una medida de importancia semántica. Para apoyar la interpretación exploratoria he generado wordclouds globales y específicos para cada evento, para visualizar exclusivamente las síntesis, los patrones léxicos y las diferencias macroscópicas entre las crisis, pero no he interpretado ninguna de ellas como medidas cuantitativas rigurosas y no tienen ningún valor inferencial para los fines del proyecto.

Para profundizar en las diferencias lingüísticas entre las crisis, decidí realizar un análisis basado en la medida TF-IDF (Term Frequency-Inverse Document Frequency), calculada a nivel de evento. En este contexto, cada evento se trata como un "documento" agregado y la TF-IDF se utiliza para identificar los términos que son relativamente más distintivos de una crisis que las otras. Este análisis permite visualizar las especificidades lexicales y tematizaciones recurrentes asociadas a cada evento, sin necesidad de utilizar modelado temático, lo que no es coherente con la brevedad de los títulos periodísticos. Las señales de la TF-IDF fueron interpretadas como señales de diferenciación lingüística, no como categorías temáticas latentes. En la última parte de esta fase de análisis, integré el corpus de los tokens junto con el indicador de atención mediática derivado del dataset Mentions. Para garantizar la compatibilidad de la unión he reducido a un formato estándar las variables temporales, esta integración se ha realizado a nivel evento-día-dominio, de manera que asocie a cada token el número de menciones diarias generadas por la fuente que publicó el título.

Utilizando la distribución de menciones, clasifiqué los días en tres categorías de atención (alta, media y baja), usando cuartiles como umbrales. Clasificándolo todo así pude comparar el lenguaje de los títulos publicados en contextos de alta visibilidad mediática con aquellos en fases de menor atención. En la práctica relaciona la frecuencia de las palabras con el nivel de atención mediática, permitiendo observar cuáles son los términos más frecuentes en los días caracterizados por una cobertura intensa. En esta fase he querido analizar la atención mediática asociada a cada crisis geopolítica, utilizando el dataset Mentions de GDELT, no para evaluar el contenido informativo de los artículos sino con el fin de medir la intensidad y la evolución temporal de la cobertura mediática, vista como volumen total de citas generadas en el espacio informativo global. Este análisis parte del conjunto de datos de las

menciones diarias preprocesadas previamente (gdelt_mentions_daily.csv) del archivo Translation Mentions. Aquí cada observación representa el número de menciones asociadas a un dominio determinado, en un día determinado y para un evento de estudio específico. Luego decidí agregar esta información para obtener una medida de la atención general de los medios. En primer lugar, he agregado las menciones a nivel evento-día, sumando el número de citas, generadas por todas las fuentes informativas. Haciendo esto, pude construir una serie temporal diaria de la atención de los medios sobre el volumen total de cobertura. La agregación se ha hecho tratando de mantener lo más coherente posible la unidad de tiempo de los análisis anteriores, para garantizar la compatibilidad entre los eventos.

El conjunto de datos obtenido es un resultado que representa una medida directa de la intensidad diaria de la cobertura mediática, que luego utilicé como base para dos análisis descriptivos principales. El primer análisis se refiere a cómo evoluciona temporalmente la atención mediática, trazando una serie temporal que muestra la evolución diaria del número total de menciones durante la ventana temporal seleccionada. He elegido construir la visualización en cuestión por separado para cada crisis, para resaltar posibles picos, fases de crecimiento o caídas rápidas de la atención, coherentes con la idea de choques informativos y dinámicas no lineales de la agenda mediática. En cuanto al segundo análisis, he sintetizado la atención mediática a través de una medida de intensidad media. En la práctica, para cada acontecimiento se calcula el número medio de menciones diarias, junto con su desviación típica. Esta medida me ha permitido comparar las crisis en términos de nivel medio de visibilidad en el espacio informativo global, proporcionando así un indicador comparativo de la relevancia mediática global. Los valores medios se muestran en un gráfico de barras, que he elegido ordenar por orden decreciente para comparar mejor los diferentes estudios de caso. También en este caso es importante subrayar que las menciones han sido interpretadas solo como proxys cuantitativos de la atención mediática, el dataset Mentions mide exclusivamente la circulación y republicación de las noticias en el ecosistema mediático, Reflejando dinámicas de visibilidad y amplificación, en comparación con la recepción individual de las noticias.

Estos dos análisis en su conjunto me han proporcionado una base sólida para vincular los análisis sucesivos de framing semántico y PNL con los niveles de atención mediática observados a lo largo del tiempo, interpretando los resultados textuales solo a la luz de su relevancia en la resonancia informativa. En esta fase del proyecto he querido realizar un análisis del framing semántico de la cobertura periodística utilizando las Global Content Analysis Measures (GCAM) integradas en el GKG de GDELT. El objetivo de este análisis no es la interpretación del significado de los artículos individuales, ni la inferencia sobre estados emocionales o sobre las intenciones comunicativas de los artículos, sino la observación de la dinámica temporal de las señales semánticas, Evaluando cómo la relevancia de atributos lexicales específicos evoluciona en el contexto informativo global durante las fases iniciales de inestabilidad geopolítica. Como se mencionó anteriormente, las señales GCAM son medidas automáticas basadas en patrones y diccionarios léxicos calculados por el GDELT a través de sus tuberías NLP multilingües. En este trabajo he elegido interpretar estas señales como indicadores lingüísticos agregados, porque creo que pueden ser útiles para describir las variaciones en el lenguaje mediático a lo largo del tiempo, no como indicadores psicológicos o conductuales.

Este análisis se realizó a partir del conjunto de datos GKG preprocesado, conservando únicamente los documentos para los que el campo GCAM estaba disponible y no nulo, para garantizar la exhaustividad de la información. Cada documento que contiene el campo GCAM, originalmente codificado por cadena que asocia cada código GCAM con un valor numérico, se sometió a una fase de análisis para convertirlo en un formato estructurado. Elegí esta operación para poder obtener una

representación long de los datos GCAM, en la que cada observación corresponde a un par código-valor específico, asociado al evento de referencia, la fecha de publicación y el dominio de la fuente. Una vez que obtuve el dataset GCAM en formato largo, he agregado en este caso a nivel evento-día-frame, calculando para cada código GCAM el valor medio diario, para enfocarme mejor en las dinámicas colectivas del framing mediático. Dado que los valores de GCAM no son directamente comparables en términos absolutos, cada cuadro se normalizó mediante z-score por separado para cada evento. Esta normalización me ha permitido interpretar los valores como desviaciones relativas respecto al comportamiento medio del frame dentro de la crisis específica, haciendo comparables las variaciones temporales y facilitando la identificación de los picos, las inversiones o fases de estabilidad del framing semántico.

Para analizar la relación entre el framing semántico y la visibilidad informativa, he agregado el dataset GCAM con la medida de atención mediática derivada del dataset anterior Mentions. En particular he agregado las menciones a nivel evento-día, obteniendo una medida sintética del volumen total de la cobertura mediática diaria. La integración se ha realizado con el uso de evento y fecha como claves comunes, asociando así cada observación GCAM al nivel correspondiente de atención mediática. También aquí la atención luego fue interpretada como proxy cuantitativo de la visibilidad de las noticias en el contexto informativo global. Dado que las señales GCAM tenían una alta dimensionalidad, opté por concentrar el análisis en un subconjunto de cuadros seleccionados según su variabilidad temporal. Para cada evento he calculado la desviación estándar de los valores normalizados (z-score) de cada frame, y luego he seleccionado aquellos que se caracterizan por una mayor variabilidad en el tiempo. Procediendo de esta manera pude enfocarme en las dimensiones semánticas que muestran reales dinámicas temporales durante las fases de la crisis, evitando así marcos estables y poco informativos desde el punto de vista de la evolución del discurso mediático. Los marcos GCAM que seleccioné se analizaron con visualizaciones temporales para mostrar la tendencia de las señales normalizadas a lo largo del tiempo, junto con la tendencia de la atención de los medios, que reporté en escala normalizada.

Este análisis me ha permitido observar las posibles co-variaciones entre el framing semántico y la intensidad de la cobertura, sin formular ninguna hipótesis de causalidad o dependencia directa. Este análisis tuvo un objetivo descriptivo y exploratorio para identificar patrones de tiempo y relaciones observables en el espacio informativo, no estimar causas o construir modelos predictivos. Los resultados fueron luego interpretados como señales para comprender la reorganización del lenguaje mediático durante choques informativos y cómo esta reorganización se sitúa en relación con los niveles de atención observados anteriormente. Una vez que he caracterizado la evolución temporal de los marcos semánticos GCAM para cada evento de estudio, mi enfoque metodológico se ha desplazado hacia la exploración de la relación temporal entre el encuadre semántico y la atención mediática. No para introducir nuevas medidas del contenido, sino para relacionar las señales semánticas ya analizadas con la visibilidad informativa observada.

Este segundo análisis se basó en el dataset `gcam_framing_daily.csv`, que integraba para cada evento y día los valores medios normalizados (z-score) de los marcos GCAM con el número total de menciones diarias. Para hacer el análisis en cuestión más interpretable me he enfocado solo en las señales más relevantes, eligiendo un limitado número de frames GCAM, en particular antes los ordené por la intensidad media absoluta de su z-score en el período considerado, entonces he mantenido solo aquellos con mayor variabilidad semántica en general. Por lo tanto, elegí centrar la atención en los cuadros que mostraban las dinámicas temporales más marcadas, evitando añadir señales estables o marginales. Los valores seleccionados se agregaron a nivel de evento-día y se relacionaron con la

atención mediática normalizada. El número de mención se ha transformado en una escala común, para poder comparar las tendencias temporales con diferentes órdenes de magnitud. El resultado de todo esto ha sido una representación de la evolución temporal de los marcos semánticos GCAM y de la atención mediática, visualizada con series temporales para cada uno de los eventos del estudio, mientras que he creado también en los gráficos una línea punteada que indica la tendencia normalizada de la atención mediática. Con el objetivo final de ver cómo las variaciones del lenguaje mediático se desarrollan en concomitancia con fases de mayor o menor visibilidad informativa.

Después de analizar la atención mediática y el encuadre semántico a nivel agregado mediante GDELT, el proyecto en cuestión prevé una fase de profundización textual sobre una muestra seleccionada de artículos. El objetivo de esta fase no es ampliar el análisis a todos los contenidos textuales que tenemos disponibles en nuestro conjunto de datos, sino obtener una muestra controlada de artículos que sean de alta visibilidad, porque he considerado que esto puede ser útil para validar cualitativamente y descriptivamente los patrones observados en los análisis anteriores. La selección de la muestra de los artículos se ha hecho a partir del panel analítico evento-día-dominio (`gdel_panel.csv`), que integra tanto contenidos informativos como atención mediática. Primero eliminé los registros sin URL válida o duplicados, para garantizar la unicidad de las fuentes y la accesibilidad del contenido. Luego, para cada evento de estudio, seleccioné los 50 artículos con el mayor número de menciones, utilizando el número de citas como criterio relevante. De esta manera he centrado el análisis en contenidos que han tenido mayor resonancia en el espacio mediático global, evitando seleccionar al azar los artículos. A cada artículo seleccionado se ha asociado una variable para documentar el criterio de selección ("`top_mentions_by_event`"). El conjunto de datos resultante (`articles_to_scrape.csv`) contiene solo la información necesaria para el scraping y representa el subconjunto objetivo del corpus.

La fase de raspado se creó deliberadamente para extraer solo una porción limitada y comparable del contexto textual de los artículos seleccionados, evitando extraer todo el corpus de los artículos. Para cada URL seleccionada se realizó una solicitud HTTP con verificación del estado de la respuesta y con el uso de un user-agent declarado para fines académicos. En presencia de errores HTTP, tiempo de espera y contenido no accesible, el artículo fue marcado automáticamente con un estado y excluido de las etapas posteriores del análisis, mientras que para los artículos directamente accesibles se extrajeron dos elementos principales: el título HTML de la página y una parte del texto inicial del artículo. En particular, solo se seleccionaron párrafos con una longitud mínima predefinida para excluir el contenido marginal o no informativo. El texto final que luego se asoció al artículo está constituido por la unión de los tres primeros párrafos válidos para poder captar la introducción narrativa e informativa del artículo, tratando de mantener un nivel de comparabilidad entre diferentes fuentes. El proceso de raspado también incluye un control de calidad del contenido extraído para excluir los artículos con texto insuficiente o no válido. El resultado de esta fase es un conjunto de datos estructurado (`scraped_articles.csv`) que documenta, para cada artículo presente, el estado del scraping y el contenido textual efectivamente extraído y disponible para el análisis.

Los artículos correctamente raspados han sido sometidos a una fase de preprocessing textual distinta, en comparación con la aplicada anteriormente a los títulos. En esta fase he mantenido exclusivamente los artículos con estado de scraping válido y con contenido textual efectivamente disponible y utilizable. El texto se ha normalizado con una conversión a minúsculas, la eliminación de las entidades HTML que aún podrían estar presentes, la eliminación de caracteres no alfabéticos o en símbolos y la reducción de los espacios múltiples. No se han aplicado técnicas de stemming o lematización, ya que el objetivo no es el análisis lingüístico profundo, sino construir un corpus

coherente y comparable para análisis descriptivos. El texto estandarizado fue entonces tokenizado, tomando y tratando cada palabra como una unidad lexical básica. Eliminé los stopwords del idioma inglés y filtré los tokens de menos de cuatro caracteres para reducir el posible ruido sintáctico. Las operaciones de tokenización y gestión del corpus se han implementado utilizando el paquete `tinytext`, mientras que las fases de filtrado, agregación y normalización de frecuencias se han gestionado mediante `dplyr`.

El resultado de este proceso fue un dataset estructurado de tokens (`text_tokens.csv`) que es el corpus textual de los artículos con una alta atención mediática. Después de construir el corpus de los tokens textuales, se realizó una comparación exploratoria entre el lenguaje de los títulos y el del contenido de los artículos. Con este fin, luego comparé las frecuencias de los tokens extraídos de los textos con las frecuencias globales de los tokens de los títulos, previamente calculadas. Para hacer los dos conjuntos comparables, he normalizado las frecuencias en términos relativos dentro de cada fuente (títulos vs contenido textual). Esta comparación permite observar las diferentes diferencias y superposiciones en el léxico utilizado en los títulos con respecto al empleado en el cuerpo de los artículos, sin formular inferencias causales o interpretaciones semánticas profundas. Los resultados de esta fase se han guardado en un conjunto de datos dedicado (`title_vs_text_top_words.csv`), que contiene las palabras más representativas para cada fuente. Para completar el análisis exploratorio he generado un wordcloud de los tokens del texto raspado, con fines puramente descriptivos e ilustrativos para hacer una síntesis del léxico dominante de los artículos muestreados. Al final, esta fase sirve para dar una explicación concreta a los números surgidos del análisis, es una profundización de nuestros datos y del método estadístico utilizado.

Para complementar el análisis temporal y semántico llevado a cabo sobre los datos GDELT, he optado por incluir un análisis de red destinado a explorar la estructura relacional de la cobertura mediática global. En particular, el objetivo final de esta fase es la reconstrucción y el análisis de una red de cocobertura entre dominios informativos, para identificar patrones de centralidad, concentración e intermediación en el contexto informativo internacional durante las crisis seleccionadas. La red se ha construido a partir del panel analítico evento-día-dominio (`gdelt_panel.csv`). La unidad de análisis relacional está constituida por la co-ocurrencia de dos dominios informativos en la cobertura del mismo evento en el mismo día. Para cada par (evento, fecha), se identifican los dominios únicos con al menos un contenido publicado, y luego se generan todos los pares de dominio-dominio posibles. Cada pareja dominio-dominio representa un arco no direccional, porque la relación de cocobertura no implica ninguna direccionalidad, influencia o cita recíproca, sino solo una compartición temporal de la información. Los nodos de la red corresponden a los dominios de las fuentes periodísticas, mientras que los arcos son las relaciones de co-presencia en el mismo contexto informativo diario. La unidad temporal de la construcción de la red es, por tanto, evento-día, para garantizar coherencia con los análisis anteriores de atención mediática y framing semántico. Las relaciones dominio-dominio que generé a nivel evento-día se agregaron posteriormente durante todo el período de observación.

El peso de cada arco se define como el número de días en los que el mismo par de dominios ha cocubierto el mismo evento. Este peso representa una medida de persistencia e intensidad de la relación informativa, distinguiendo los vínculos estructurales recurrentes de las co-ocurrencias esporádicas. Para continuar, con el fin de reducir el ruido informativo y limitar el análisis a relaciones estructurales relevantes, se ha aplicado un filtro de robustez en los arcos, de modo que solo puedan mantenerse los pares de dominios con al menos cinco co-ocurrencias durante el período que he elegido analizar. Este umbral me ha permitido excluir las relaciones episódicas o accidentales, tratando de centrar la atención exclusivamente en las conexiones más estables y sistemáticas en el


contexto informativo. La red resultante he optado por modelarla como una red no dirigida y ponderada, donde los nodos son dominios informativos, los arcos representan relaciones de cocobertura y los pesos de los arcos reflejan la frecuencia de dichas relaciones. No se introduce ninguna hipótesis de causalidad, influencia editorial o dirección del flujo informativo. En la red entonces filtrada he calculado tres métricas de centralidad, utilizando el paquete igraph, incluyendo: el grado centrality, es decir, el número de conexiones de cada dominio que también representa el nivel de integración de la fuente en el flujo global de información, la centralidad betweenness, calculado en forma normalizada, que intenta capturar el papel de intermediario estructural de un dominio al conectar las diferentes partes de la red construida, y como tercera métrica la centralidad eigenvector, que mide la centralidad de un nodo con respecto a la centralidad de sus vecinos, Identificando así los dominios incluidos en los núcleos de información más influyentes.

Estas métricas se han interpretado en un sentido estructural, como propiedad de la topología de red, no como indicadores de calidad o orientación editorial del contenido. A efectos de la visualización gráfica de la red he considerado oportuno, transformar los pesos de los arcos con una función $\log(1+\text{weight})$. Gracias a esta normalización logarítmica he podido reducir la fuerte asimetría en la distribución de las co-ocurrencias, evitando que unas pocas relaciones de muy alto peso dominaran exclusivamente la visualización de la representación, Esto me permitió mejorar la legibilidad de la estructura reticular. La disposición de los nodos en el espacio se hizo eligiendo un diseño force-directed del tipo Fruchterman-Reingold, pesado sobre los valores normalizados de los arcos. El diseño se ha calculado con muchas iteraciones, para favorecer la estabilización de la configuración y limitar los fenómenos de colapso visual. Las visualizaciones finales producidas tienen una función exploratoria y descriptiva. Para investigar más a fondo la estructura de la red central, decidí aislar un subgrafo compuesto por los 20 mejores dominios con el grado más alto. Este subgrafo representa el núcleo de la red de atención mediática, es decir, todas las fuentes más interconectadas en términos de cocobertura. El análisis posterior del núcleo permitió resaltar los nodos dominantes en el espacio informativo global y observar la densidad de las relaciones entre las principales fuentes. En conclusión, el análisis de red no tiene como objetivo explicar el contenido de la información interna de los artículos, ni modelar procesos hipotéticos de difusión causal de las noticias entre los diferentes actores. Constituye un instrumento descriptivo y estructural, para integrar el análisis de atención mediática y framing semántico, con el fin de proporcionar también una representación de la configuración relacional del ecosistema mediático durante las crisis geopolíticas analizadas.

Resultados


A partir de los resultados del análisis temporal de la atención mediática, que he medido utilizando el número diario de menciones en los medios globales, se destacan las tendencias distintas en las fases iniciales de las tres crisis geopolíticas analizadas en el proyecto: guerra en Ucrania, escalada del conflicto en Gaza y crisis político-institucional en Venezuela.

Evolución de la atención mediática en las fases iniciales de las crisis
Número diario de menciones en medios globales (GDELT)




La evolución de la atención mediática asociada a la guerra en Ucrania muestra una dinámica muy concentrada en los primeros días posteriores a la invasión rusa, con el pico extremo pronunciado en la fecha entre el 24 y el 25 de febrero. Estos días se caracterizaron por el inicio del ataque militar a gran escala, los bombardeos en la capital Kiev y otras principales ciudades ucranianas e incluso la ocupación de la zona de Chernóbil. Esta tendencia es coherente con la configuración de un choque informativo repentino, similar a los eventos geopolíticos de alta intensidad. Los días siguientes están marcados por las primeras sanciones contra Rusia por parte de la Unión Europea y Estados Unidos, de hecho la cobertura comienza a fragmentarse debido a los múltiples desarrollos del conflicto. Los días 26 y 27 de febrero, la atención comienza a disminuir en relación con eventos de carácter predominantemente económico y estratégico, la exclusión del sistema SWIFT para las instituciones bancarias rusas, la autorización de envío de armas por parte de Alemania y el anuncio de la alerta nuclear para las fuerzas rusas introducen nuevas dimensiones interpretativas en la cobertura mediática, donde asistimos a una reestructuración del discurso informativo global, hay una caída neta que representa el final de la saturación inicial, el evento de invasión ya no es el único tema dominante. Del 28 de febrero al 5 de marzo ya no vemos el pico inicial, pero la atención sin embargo decimos que no colapsa, en realidad tenemos oscilaciones modestas con subidas, pequeñas caídas y niveles bastante estables. Este patrón es porque no tenemos un solo evento dominante sino más eventos relevantes distribuidos en el tiempo como la aparición de temas relacionados con las consecuencias humanitarias del conflicto, los riesgos sistémicos de la guerra y los desarrollos político-diplomáticos, la caída de Kherson, los debates internacionales en las Naciones Unidas y las preocupaciones sobre la seguridad nuclear. La atención mediática asociada a la crisis de Gaza muestra una dinámica más progresiva y menos concentrada que en el caso ucraniano, el gráfico muestra un crecimiento gradual de las menciones en los días posteriores al 7 de octubre, hasta alcanzar su valor máximo entre el 11 y el 12 de octubre. Esta tendencia sugiere que la saturación de la agenda mediática no es inmediata, sino que se construye a lo largo del tiempo con la acumulación de desarrollos militares, políticos y humanitarios. En la fase final del período analizado se registra una nueva subida de la atención, coherente con el surgimiento de eventos de alto impacto simbólico y humanitario, en particular la explosión en el hospital Al-Ahli el 17 de octubre. En general, la atención mediática de la crisis de Gaza en el período seleccionado se configura como un caso intenso de atención mediática, construido de forma incremental con más momentos de reactivación que un choque inicial. La atención mediática a la crisis venezolana presenta una intensidad relativamente menor que los otros dos casos de conflicto armado, el gráfico muestra niveles de cobertura más contenidos y variabilidad moderada, sin la presencia de un choque informativo repentino. La atención también en este caso crece de manera

fragmentada y gradual, coherente con la naturaleza de la crisis principalmente político-institucional. El pico de la ventana de tiempo se refiere al 3 de enero de 2025 que coincide con una fuerte presión diplomática internacional, donde varios actores internacionales y la Unión Europea cuestionan la legitimidad efectiva del gobierno en vista de la toma de posesión presidencial. Posteriormente la atención tiende a disminuir, y en el conjunto la crisis venezolana es más un caso de atención mediática sostenida pero no explosiva.




Para completar el análisis temporal, también se calculó la intensidad media de la atención mediática para cada crisis, medida como el número medio diario de menciones en el período tomado en caso del proyecto. Los resultados muestran que la guerra en Ucrania presenta el nivel más alto de atención entre los tres casos analizados. La crisis de Gaza sigue con un valor medio muy poco inferior y por último la crisis en Venezuela que registra un nivel de atención sensiblemente más bajo en comparación con los otros dos acontecimientos. Esta comparación nos permite ver cómo las crisis pueden diferir no solo en la forma temporal de la cobertura, sino también en la cantidad de espacio informativo ocupado en los medios en las etapas iniciales. Los resultados preliminares indican una respuesta diferenciada de la atención de los medios globales a los eventos críticos. El alcance volumétrico es máximo e inmediato para los conflictos bélicos de alta intensidad, mientras que es más modesto para las dinámicas político-institucionales. Esta diversidad constituye el punto de partida para los análisis posteriores, proporcionando el contexto semántico y reticular necesario para interpretar las dinámicas lingüísticas observadas a la luz de los diferentes niveles de visibilidad inicial.



De los resultados del análisis del framing semántico, con el uso de las señales GCAM, (ej. c15.99, c9.73) códigos de referencia de los diccionarios léxicos estándar utilizados en NRC (NRC Emotion Lexicon, Harvard IV-4, WordNet, VADER), utilizados en este trabajo exclusivamente como sustitutos lingüísticos agregados para observar la variación temporal relativa del lenguaje durante las fases iniciales de las tres crisis. Los resultados muestran en lo que respecta a Ucrania una fuerte volatilidad semántica en los primeros días después de la invasión, con el pico inicial de la atención mediática. Las oscilaciones son muy amplias y sobre todo no sincronizadas, indicando una fase de reestructuración rápida del discurso informativo. En los días siguientes, como se mencionó anteriormente, la variabilidad de los marcos se reduce y las tendencias son consistentes con la consolidación del marco después de la fase de shock inicial. En cuanto al conflicto de Gaza, el análisis del framing semántico muestra una situación diferente al caso ucraniano, las señales GCAM evidencian una dinámica altamente fragmentada, también aquí caracterizada por la coexistencia de varios frames con tendencias bastante divergentes. Las señales semánticas en cuestión no convergen demasiado hacia un único marco dominante, sugiriendo una cierta pluralidad de marcos interpretativos que con el tiempo se reorganizan de manera no lineal coherente con la complejidad de un contexto de noticias asociado a la crisis. En la crisis de Venezuela, por el contrario, los marcos GCAM muestran una configuración diferente a los conflictos armados anteriores. La atención mediática es más contenida y estable relativamente en el tiempo considerado. Las señales muestran variaciones semánticas puntuales, con un pico alrededor de finales de diciembre, seguido por una rápida vuelta a los niveles medios. En su conjunto, este encuadramiento parece caracterizarse por una estabilidad relativa, coherente con coberturas institucionales y diplomáticas, más que por una escalada repentina. En apoyo de los resultados del análisis descrito, la siguiente figura muestra cómo evolucionan con el tiempo los principales marcos GCAM seleccionados, considerándolos en este caso sin la evolución de la atención mediática.


Evolución temporal de los principales frames GCAM



Continuando luego tenemos los resultados del análisis textual exploratorio realizado sobre el subconjunto seleccionado de artículos con una alta atención mediática. En particular, aquellos con el mayor número de menciones para cada evento, a fin de profundizar cualitativamente el lenguaje utilizado en el espacio informativo global. Como resultado de los procedimientos de scraping y los controles de calidad, la muestra final analizada resultó compuesta por 91 artículos con texto válido, distribuidos solo en los casos de Gaza y Venezuela, mientras que para la guerra en Ucrania no fue posible obtener un número de contenidos textuales utilizables, especialmente en nuestra muestra seleccionada, esto limitó el análisis a solo dos eventos. El corpus resultante, comparable y coherente, está compuesto por 4000 tokens distintos, que representan el léxico real de los párrafos de los

configurándose como una red no directa y ponderada, caracterizada por una estructura densa y concentrada. El análisis de las métricas de centralidad muestra una fuerte concentración de la red alrededor de un número limitado de nodos centrales. En particular los dominios como yahoo.com, news.yahoo.com, aol.com y dailymail.co.uk emergen como primeros principalmente en las tres métricas consideradas: degree centrality, betweenness centrality y eigenvector centrality. La recurrencia de estos dominios sugiere la existencia de un núcleo informativo estable que ocupa la posición central en la estructura del ecosistema mediático global tomado en estudio.

**Red de Atención Mediática entre Dominios
(Estructura global, enlaces fuertes)**




Interpretativamente, el grado de centralidad nos indica cómo estos dominios están fuertemente integrados en el flujo general de información, compartiendo la cobertura de los eventos con un gran número de otras fuentes. La centralidad de la interrelación, para los dominios en los que es alta, señala el papel de intermediación estructural sugiriendo como tales dominios conectan porciones diferentes de la red y facilitan la circulación sincronizada de la atención mediática. Finalmente, los altos valores de centralidad eigenvector indican que para algunos dominios además de estar muy conectados, también están conectados a otros nodos muy centrales, reforzando la posición en el núcleo de la red. La visualización de arriba muestra claramente una estructura que puede atribuirse a un modelo core-periphery. En el centro de la red un grupo restringido de dominios muy conectados entre sí y también numerosos periódicos nacionales o locales que se sitúan en posición periférica, pero con fuerte vínculo con el núcleo central. Esta visualización sugiere una fuerte dependencia entre los medios globales y locales, donde las fuentes periféricas se sincronizan con un conjunto de centros centrales de información.


rank	domain	degree	betweenness	eigenvector	top_metric
1	dailymail.co.uk	337	0.19204807	0.9775614	Betweenness
2	yahoo.com	335	0.14879496	1.0000000	Betweenness
3	aol.com	249	0.08134604	0.8426431	Betweenness
4	news.yahoo.com	260	0.06381321	0.8861484	Betweenness
5	cbc.ca	194	0.04165261	0.7173185	Betweenness
1	dailymail.co.uk	337	0.19204807	0.9775614	Degree
2	yahoo.com	335	0.14879496	1.0000000	Degree
3	news.yahoo.com	260	0.06381321	0.8861484	Degree
4	aol.com	249	0.08134604	0.8426431	Degree
5	cbc.ca	194	0.04165261	0.7173185	Degree
1	yahoo.com	335	0.14879496	1.0000000	Eigenvector
2	dailymail.co.uk	337	0.19204807	0.9775614	Eigenvector
3	news.yahoo.com	260	0.06381321	0.8861484	Eigenvector
4	aol.com	249	0.08134604	0.8426431	Eigenvector
5	cbc.ca	194	0.04165261	0.7173185	Eigenvector

El análisis posterior del subgrafo compuesto por los 20 dominios con el grado más alto refuerza aún más la evidencia del análisis de la red global, pone aún más en evidencia un núcleo informativo compacto y densamente interconectado, que es el núcleo estructural del ecosistema mediático observado. Dentro de este subgrafo los dominios centrales están conectados entre sí de manera muy fuerte, indicando también una alta co-presencia en la cobertura de las crisis geopolíticas analizadas. La estructura del núcleo tiende a organizarse en torno a un conjunto de centros globales de información, formados principalmente por medios generalistas con amplia difusión y plataformas agregadoras. Estos dominios son esenciales para conectar la información a nivel nacional y local, asegurando que la cobertura sea uniforme y coherente entre las diferentes áreas geográficas.

Top 20 Dominios más Centrales (Core de Atención Mediática)



Red de Atención Mediática entre Dominios



Conclusiones

Este proyecto ha analizado la cobertura mediática global de tres crisis geopolíticas, utilizando un enfoque integrado e híbrido, basado en datos estructurados procedentes de contenidos originalmente no estructurados (GDELT), y también datos textuales no estructurados obtenidos a través del scraping dirigido de los artículos con alta visibilidad. Combinando el análisis temporal de la atención mediática, el encuadre semántico a través de GCAM, el análisis textual exploratorio y el análisis de red, el trabajo ha intentado proporcionar una lectura a varios niveles de las dinámicas informativas en las fases iniciales de las crisis. Los resultados mostraron que la atención de los medios globales responde de manera diferente dependiendo de la naturaleza del evento. La guerra en Ucrania, por

ejemplo, representa un choque informativo repentino con una intensidad muy alta, seguido de una rápida saturación de la agenda mediática y una reorganización del discurso informativo después de los primeros tres días principales. El conflicto en Gaza, por otro lado, presenta dinámicas más incrementales, con momentos de reactivación de la atención y más fragmentación temporal y semántica. Por último, en cambio, la crisis venezolana destaca niveles de atención contenidos y estables, coherentes con una cobertura que ve principalmente una crisis institucional y diplomática. El análisis de framing confirma estas diferencias descritas, porque nos muestra una fuerte volatilidad inicial del frame en el caso ucraniano, una pluralidad de interpretaciones en cambio en el caso de Gaza y una relativa estabilidad en el caso de la crisis venezolana. Esto sugiere que las dinámicas lingüísticas evolucionan junto con la intensidad de la atención mediática, pero también reflejan cómo el modo de hacer información cambia y se reestructura según el tipo de emergencia afrontada. El análisis textual exploratorio, realizado sobre el subconjunto, tiene un valor principalmente descriptivo y de apoyo a los análisis cuantitativos anteriores de este proyecto. Por último, el análisis de la red ha puesto de manifiesto que la cobertura mediática global de las crisis geopolíticas gira en torno a una estructura tipo centro-periferia, con un núcleo restringido por dominios fuertemente centrales que tienen un papel clave en coordinar y sincronizar la atención informativa internacional. Esta estructura ayuda a entender cómo la atención del público y la forma de presentar las noticias están relacionadas entre sí. Todo esto ocurre en un sistema de información donde las fuentes están estrechamente conectadas y dependen de unos pocos centros principales. El trabajo en cuestión presenta algunas limitaciones que consideran oportuno aclarar, en primer lugar el análisis se centra solamente en las fases iniciales de las crisis seleccionadas en cuestión, limitando así la observación de dinámicas a largo plazo, como la actual continuación y evolución de la guerra en Ucrania y el conflicto en Gaza, y también limitando los procesos de normalización de la cobertura mediática. En segundo lugar, las señales GCAM, al estar basadas en diccionarios léxicos estandarizados, solo representan un proxy lingüístico agregado que no permite captar todos los matices contextuales o las interpretaciones discursivas más profundas del análisis textual. El análisis textual llevado a cabo entonces se basa solamente en el subconjunto reducido de artículos con alta visibilidad y solo para dos de los tres eventos considerados, por problemas y limitaciones de disponibilidad en el scraping. Por último, el análisis de la red se interpretó en términos estructurales, sin introducir hipótesis sobre la influencia entre los diferentes editores, la difusión aleatoria o las dinámicas de agenda-setting. Aunque esta elección es coherente con los objetivos de este proyecto, limita la posibilidad de sacar conclusiones sobre los mecanismos de la información entre medios.

Referencias

- Leetaru, K., & Schrod, P. A. (2013). GDELT: Global data on events, location, and tone. Paper presented at the ISA Annual Convention. Página web. <https://www.gdeltproject.org/>
I dati utilizzati provengono dal Global Knowledge Graph (GKG) e dal dataset Mentions del progetto GDELT.
- GDELT Project. (2019). GDELT Global Knowledge Graph Codebook Version 2.1 [Documento técnico]. GDELT Project.
http://data.gdeltproject.org/documentation/GDELT-Global_Knowledge_Graph_Codebook-V2.1.pdf
- McCombs, M. E., & Shaw, D. L. (1972). The agenda-setting function of mass media. *Public Opinion Quarterly*, 36(2), 176–187. <https://doi.org/10.1086/267990>

Baumgartner, F. R., & Jones, B. D. (1993). *Agendas and instability in American politics*. University of Chicago Press.

Cavari, A., & Efrat, A. (2025). Polarized public agenda in times of crisis. *Journal of European Public Policy*. <https://doi.org/10.1080/13501763.2025.2552418>

Entman, R. M. (1993). Framing: Toward clarification of a fractured paradigm. *Journal of Communication*, 43(4), 51–58. <https://doi.org/10.1111/j.1460-2466.1993.tb01304.x>