

Progetto Dati non strutturati

Introduzione

Negli ultimi anni, e specialmente in maniera molto evidente nel contesto contemporaneo, le crisi geopolitiche sono state accompagnate da un ampliamento significativo del tempo e dello spazio che i media dedicano alla loro copertura. Questo aumento non riguarda esclusivamente la natura quantitativa, ma riguarda come prima cosa le modalità attraverso cui gli eventi vengono narrati, contestualizzati e inseriti in cornici interpretative più ampie. La risonanza mediatica tende a mantenere una grande continuità narrativa nel tempo, producendo risultati che portano a ridefinire la percezione della rilevanza degli eventi nel dibattito pubblico. In secondo luogo, nel contesto informativo contemporaneo, l'informazione assume un ruolo assoluto di strategia: perché parlare di una crisi, selezionare determinati temi e decidere a quali di questi attribuire visibilità può contribuire a orientare il contesto informativo entro cui gli eventi vengono interpretati. Infine, l'integrazione dei media tradizionali e piattaforme digitali ha terribilmente accentuato la dimensione globale dell'informazione, rendendo possibile che eventi locali acquisiscono rapidamente una risonanza globale, su qualsiasi piattaforma, finendo al centro del dibattito pubblico. In questo quadro, l'attenzione mediatica, intesa come capacità dei media di selezionare, tematizzare ed enfatizzare specifici eventi, rappresenta un concetto chiave per comprendere come le crisi geopolitiche vengano organizzate e narrate nello spazio informativo internazionale. La letteratura suggerisce che l'agenda informativa globale non segua un'evoluzione lineare, ma è piena di discontinuità e punti di svolta innescati da eventi critici improvvisi talvolta, capaci di catalizzare e riorientare in un istante l'attenzione dei media. Queste dinamiche sono coerenti con *l'idea di attenzione non lineare* (Baumgartner & Jones, 1993) e con i principi fondativi dell'*agenda-setting* (McCombs & Shaw, 1972), secondo cui gli eventi salienti possono ridefinire temporaneamente le priorità informative. L'analisi di queste dinamiche incontra una sfida metodologica molto importante: la maggior parte delle informazioni prodotte dai media sono di natura testuale non strutturata, difficile da interpretare al contrario di indicatori quantitativi. I dati non strutturati come i testi giornalistici nei loro contenuti contengono informazioni che vanno oltre la frequenza di notizie, infatti essi hanno un linguaggio caratteristico in base alla regione di provenienza, hanno temi specifici che ricorrono selezionati appositamente da uno scrittore, un processo editoriale o anche convenzioni giornalistiche che enfatizzano determinati aspetti degli eventi descritti, facendo leva spesso su strategie, scelte linguistiche e retoriche per tenere il lettore incollato. Estrarre e analizzare sistematicamente questi segnali è un compito che richiede assolutamente uno strumento computazionale, che sia in grado di operare su grandi masse di dati in modo coerente e replicabile dagli altri. In questa visione si collega il seguente lavoro, che utilizza dati open provenienti dal progetto GDELT per l'analisi della copertura mediatica di tre crisi geopolitiche recenti: la guerra in Ucraina, (iniziata a febbraio del 2022) un'invasione su vasta scala che ha riportato la guerra nel cuore dell'Europa, che ha causato centinaia di migliaia di vittime, una crisi migratoria e riconfigurato radicalmente gli equilibri tra superpotenze mondiali, ma soprattutto tra la NATO e la Russia. La seconda crisi analizzata è l'escalation del conflitto a Gaza (ad ottobre del 2023), scaturito dopo la vasta e complessa offensiva militare lanciata il 7 ottobre 2023 contro Israele da Hamas, la quale ha dato il via ad una crisi umanitaria e ad un'intensificazione del conflitto senza precedenti nel Medio Oriente, oltre ad un grandissimo impatto mediatico globale che vede la scena internazionale schierata in maniera fortemente polarizzata. E come ultima crisi analizzata ho scelto quella politico-istituzionale in Venezuela (2024–2025), che vede un contesto di instabilità prolungata che ha visto un nuovo picco in seguito alle contestate elezioni presidenziali del luglio 2024, portando a un'ondata di proteste, sanzioni internazionali e un

intenso dibattito sulla legittimità democratica nel quadrante latino-americano, tutto ciò culminando negli eventi legati alla cattura e alla rimozione di Nicolás Maduro. La selezione di questi tre casi consente di confrontare la modalità di copertura mediatica relative a eventi diversi per natura, successi in aree geografiche differenti e con durate, e periodi successivamente selezionati differenti, ma tutti e tre sono accomunati da un' elevata centralità nel dibattito pubblico internazionale. GDELT project (Global Database of Events, Language, and Tone) non è un semplice archivio di articoli giorn attingendo a testate web da quasi ogni paese e in più di 100 lingue, GDELT estrae persone, organizzazioni, tematiche e segnali lessicali che muovono la società globale. Il progetto offre così una piattaforma open data che permette di analizzare computazionalmente ciò che accade nel mondo, secondo dopo secondo. I dati forniti descrivono metadati delle fonti, i volumi di menzioni degli articoli, indicatori di attenzione e segnali semantici estratti attraverso una pipeline complessa, utilizzando algoritmi di Natural Language Processing per trasformare testi non strutturati in dati codificati, ogni 15 minuti su scala globale, consentendo di osservare come l'informazione venga prodotta e distribuita nel tempo. Essendo segnali automatici, essi non rappresentano misure diretta della reale percezione, di possibili opinioni oppure delle emozioni dei lettori, al contrario si tratta di approssimazioni lessicali e quantitative utili a descrivere e capire come si muovono le informazioni nel loro insieme. L'obiettivo finale di questo lavoro non è dunque di stabilire quali sono le relazioni causali tra eventi geopolitici e quali reazioni ha l'opinione pubblica, né inferire su stati emotivi individuali, ma fornire una lettura descrittiva e comparativa delle dinamiche di attenzione mediatica di e di cornice concettuale che emergono dalla copertura delle informazioni globali. Dal punto di vista metodologico, il progetto si basa su una pipeline di analisi strutturata che integra i dati open provenienti da GDELT con tecniche di analisi testuale e di rete. I dati vengono acquisiti partendo dai file ufficiali (GDELT Translation GKG e Translation Mentions) sul portale GDELT, poi vengono selezionati all'interno di finestre temporali specifiche per ciascun evento, per garantire coerenza comparativa e focalizzarsi meglio sugli shock informativi iniziali. Successivamente i dati grezzi vengono sottoposti ad un preprocessing che include anche la verifica della struttura delle variabili, il mapping delle colonne, l'estrazione dei metadati rilevanti (ad esempio domini, date, titoli, segnali semantici), la costruzione di un panel evento-giorno-dominio e l'integrazione degli indicatori di attenzione mediatica basati sul numero di menzioni. Con questo approccio è possibile misurare non solo il significato dei dati, ma anche il loro impatto volumetrico. L'analisi del contenuto testuale è articolata in più livelli diversi. Come prima cosa, i titoli degli articoli sono stati estratti direttamente dai metadati GDELT e poi sono stati analizzati tramite metodi di NLP, includendo tokenizzazione, analisi delle frequenze, misure di distintività lessicale (TD-IDF) e confronto tra periodi di alta e bassa attenzione mediatica. Parallelamente usiamo i flussi GCAM come rappresentazioni semantiche per seguire come cambia la narrazione linguistica dei fatti. L'integrazione con i parametri di attenzione ci consente di rilevare se vi sono spostamenti comuni e dinamiche nel tempo tra la copertura mediatica e l'interesse del pubblico, capire se la maniera in cui i media parlano influenza ciò che le persone cercano o guardano. In secondo luogo, il progetto integra nella sua seconda parte anche un'analisi basata sul web scraping mirato a un sottoinsieme selezionato di articoli giornalistici con alta attenzione mediatica, individuati usando come base il volume delle menzioni, per poter infine confrontare il linguaggio dei titoli con quello sviluppato successivamente all'interno degli articoli. Questo passaggio permette di confrontare l'essenza comunicativa del titolo, che è una rappresentazione condensata, con lo sviluppo dell'articolo (narrazione estesa), distinguendo il fatto riportato dal taglio interpretativo adottato dall'autore. Infine l'analisi si conclude con l'esplorazione delle relazioni tra i vari media: costruendo diverse reti di co-copertura (giornali, siti web, TV) degli eventi. Esaminando poi queste reti tramite le misure metriche di centralità è possibile mappare la struttura dell'ecosistema informativo così da identificare quali fonti sono più influenti durante una crisi. In generale quindi le tecniche di NLP, l'analisi dei segnali GCAM e gli strumenti di analisi di

rete vengono utilizzati in chiave esplorativa e descrittiva. I risultati non vengono interpretati come interpretati come soluzioni approssimate dei fenomeni mediatici. L'analisi, al contrario, si limita a descrivere dinamiche di visibilità e tendenze lessicali emerse, evitando inferenze dirette sul vero sentiment o sulle relazioni di causa-effetto tra gli eventi e le loro narrazioni. In sintesi, la mia analisi si inserisce in un contesto di ricerca che analizza il ruolo dei media e dei flussi informativi nella rappresentazione delle crisi geopolitiche, mostrando come l'uso e l'integrazione di dati non strutturati, indicatori di attenzione e analisi relazionali possa supportare attività di monitoraggio informativo e analisi esplorative. Confrontando tre crisi differenti, il progetto mira a evidenziare similarità e differenze nei pattern di attenzione, nei contesti linguistici e nelle reti informative che emergono dalla copertura globale mediatica, contribuendo alla comprensione delle dinamiche dell'informazione internazionale.

Quadro Teorico

La base teorica dell'analisi della copertura mediatica si trova nella funzione di agenda-setting, definita da McCombs e Shaw (1972). Rappresenta la base per comprendere come i mezzi di comunicazione non servono soltanto a trasmettere informazioni, ma esercitano anche un'influenza molto importante nella gerarchia di importanza attribuita ai diversi temi globali. Un evento geopolitico diventa importante quando è possibile osservare un incremento della densità e persistenza della sua copertura nelle fonti giornalistiche. Fonti che hanno il ruolo di filtro capace di segnalare quali questioni sono centrali e quali richiedono maggiore attenzione pubblica. In un contesto, come quello attuale di dati massivi, studiare il volume delle notizie aiuta a capire quanto una crisi è saliente. Tuttavia, la salienza mediatica di un evento non ha una distribuzione uniforme nel tempo, ma segue dinamiche caratterizzate da forti discontinuità. La distribuzione dell'attenzione mediatica non è costante nel tempo e dritta, ma è descritta dalla teoria dell'equilibrio punteggiato di Baumgartner e Jones (1993). Questo modello suggerisce che i sistemi informativi sono caratterizzati da momenti stabili per lunghi periodi, che vengono interrotti da bruschi cambiamenti, o "punteggiature", in risposta a nuovi impulsi o shock che cambiano tutto. Queste dinamiche implicano che l'attenzione mediatica verso una crisi non è per nulla lineare: un evento critico è capace di saturare in pochissimo tempo l'agenda, spostando l'interesse da temi precedentemente rilevanti al nuovo centro del conflitto. Quindi, la configurazione dell'attenzione non è altro che una risorsa scarsa che si concentra su pochi eventi di grande entità. Queste dinamiche risultano particolarmente evidenti nel caso di crisi geopolitiche, le quali sono degli esempi di eventi capaci di interrompere la comunicazione ordinaria. Le crisi geopolitiche possono essere interpretate come eventi informativi improvvisi o "focusing events" che interrompono la comunicazione ordinaria e i normali processi politici, la normale routine. Secondo Cavari e Edfrat (2025), una crisi è un evento di rottura dove le istituzioni o le procedure stabili non riescono a risolvere i conflitti, generando così un senso di minaccia urgente ai valori o alle basi strutturali di una comunità. Tali shock riassessano le priorità di comunicazione, portando a una riduzione della diversità dell'agenda complessiva a favore di un focus dell'attenzione sul tema del conflitto. Soprattutto le crisi legate alla sicurezza esterna producono una solidificazione dell'agenda, dove la priorità diventa la funzione core dello stato, come la difesa e le relazioni internazionali. Oltre alla quantità di attenzione generata, le crisi differiscono anche per come vengono narrate tra loro, e interpretate nello spazio mediatico. Oltre al volume della copertura, la natura dell'informazione è determinata dal contesto informativo, inteso da Entman (1993) come la selezione di alcuni aspetti di una realtà percepita per renderli più salienti. In un approccio di analisi dei dati non strutturati, il contesto informativo non viene indagato come uno stato psicologico, ma come presenza o assenza di specifici segnali linguistici e parole che definiscono il problema. Attraverso dizionari lessicali automatici, è possibile trovare degli schemi ricorrenti nelle espressioni che caratterizzano una crisi. In

questo quadro, il sentiment o tono è usato esclusivamente come proxy lessicale automatico. Esso non è altro che la media calcolata algebricamente della positività o negatività dei termini presenti nei testi, che aiuta a fornire una maggiore descrizione quantitativa della direzione del linguaggio usato dai media senza implicare inferenze sugli stati mentali dei produttori o lettori delle notizie. L'analisi empirica di queste dinamiche richiede strumenti che siano in grado di osservare simultaneamente volumi informativi e segnali linguistici su larga scala. L'integrazione di tutti i concetti teorici elencati sopra è resa possibile dall'emergere dei sistemi news-based che monitorano su larga scala come GDELT (*Global Database of Events, Language, and Tone*), sviluppato da Leetaru e Schrodt (2013). GDELT monitora decine di migliaia di fonti giornalistiche globali in tempo reale, estraendo metadati su entità, temi e "event data" attraverso tecniche di Natural Language Processing (NLP). GDELT comprende diverse dediche all'analisi delle informazioni internazionali. In particolare, il Global Knowledge Graph (GKG) consente di mappare i temi, le entità e i segnali linguistici attraverso dizionari lessicali predefiniti, mentre il dataset Mentions permette di misurare l'intensità della copertura mediatica associata agli articoli. L'utilizzo simultaneo di queste due componenti rende possibile l'analisi comparative ed esplorative di crisi geopolitiche, collegando il variare dell'attenzione mediatica e del linguaggio giornalistico alle dinamiche temporali e alla distribuzione tra fonti informative diverse. Questo approccio permette l'analisi delle crisi geopolitiche come fenomeni informativi aggregati, offrendo la base per lo studio delle dinamiche di attenzione, dei pattern linguistici e delle relazioni tra attori mediatici, preparando l'applicazione dei metodi di analisi di rete e serie storiche.

DATI E METODOLOGIA

DATI

Come già ribadito i dati di questo lavoro provengono dal progetto GDELT. In coerenza con l'obiettivo di studiare le dinamiche di attenzione mediatica e del contesto informativo, l'analisi usa solo due delle varie componenti del database GDELT 2.1: ovvero il Global Knowledge Graph (GKG), che fornisce metadati semantici a livello di documento, in pratica include all'interno informazioni su temi, segnali linguistici avanzati, Global Content Analysis Measures (GCAM), tono lessicale, titolo dell'articolo ed anche il dominio della fonte, e il dataset Mentions che permette di misurare quanto la risonanza di una notizia nello spazio pubblico, attraverso il conteggio delle citazioni e ripubblicazioni degli articoli da parte di altre fonti. L'integrazione di questi componenti ci permette di correlare la caratterizzazione semantica degli eventi con la loro portata volumetrica, restituendoci un quadro con qualità della narrazione ed effettiva risonanza congiunte nell'ecosistema informativo. Per entrambe le componenti nel progetto sono stati utilizzati unicamente i file di traduzione (Translation GKG e Translation Mentions), per includere sistematicamente contenuti originariamente pubblicati in lingue diverse dall'inglese e ridurre potenziali bias linguistici nella comparazione internazionale, evitando quindi un'esclusiva fonte anglosassone, o prevalentemente statunitense, che farebbe riflettere le priorità editoriali e l'interesse informativo specifico di un solo contesto mediatico, compromettendo l'obiettivo di rappresentazione globale della copertura. I dati sono stati scaricati dal repository ufficiale di GDELT utilizzando il *masterfilelist*, che elenca esaustivamente i file disponibili con riferimento temporale. Per ciascun giorno incluso nelle finestre temporali selezionate per questo progetto sono stati selezionati sia un file di Translation GKG e un file di Translation Mentions. I file grezzi sono stati poi successivamente sottoposti a una fase di preprocessing che ha riguardato principalmente il verificare che la struttura delle variabili, l'estrazione dei metadati rilevanti e l'aggregazione delle menzioni a livello evento-giorno-dominio. L'integrazione quindi di GKG e

Mentions ha permesso di costruire infine un panel analitico evento-giorno-dominio, che costituisce la base comune per tutte le analisi successive effettuate.

METODOLOGIA

In una prima fase per il progetto ho definito la struttura base di come avevo intenzione di procedere, creando una directory esclusivamente per i dati e una sottocartella specifica per i file grezzi (raw), dentro alla quale poi sono stati salvati tutti i dataset scaricati. Questa organizzazione è ottimale e permette di mantenere separati i dati originali per le successive versioni pre processate, facilitando anche notevolmente il lavoro di tracciabilità, ma anche soprattutto la riproducibilità dell'analisi. Successivamente ho definito le finestre temporali di analisi per ciascun evento di studio. Questa scelta è motivata principalmente da considerazioni legate alla struttura temporale dei dati di GDELT. In particolare, per i momenti e periodi più recenti i dataset possono risultare parziali o soggetti a successive revisioni, per vari motivi di ingestione, traduzione e consolidamento delle fonti monitorate. Inoltre la scelta è motivata anche dalla sostenibilità computazionale per gestire in modo efficiente l'elevato numero di dati e garantire la replicabilità dell'intero flusso di dati. In particolare per la guerra in Ucraina è stata scelta la finestra compresa tra il 24 febbraio 2022 e il 5 marzo 2022, una finestra temporale che copre la fase iniziale dell'invasione russa dell'Ucraina, segnata dall'attacco su vasta scala e dalla prima avanzata verso la capitale Kiev. Ho reputato questo periodo come l'apice della salienza mediatica globale, caratterizzato dalle prime pesanti reazioni internazionali quali le molteplici sanzioni verso la Russia, dall'inizio di una massiccia ondata di profughi ucraini verso l'Europa e dalla drastica riconfigurazione della postura di difesa europea con una decisione di riarmo, in pratica potremmo definire questo periodo il Big Bang e gli attimi dopo. Per l'escalation a Gaza la finestra che ho scelto è compresa tra il 7 ottobre 2023 e il 17 ottobre 2023, ovvero il periodo tra lo scoppio delle ostilità come non mai visto, per l'improvvisa incursione armata di Hamas nel sud di Israele e la conseguente risposta militare su vasta scala nella Striscia di Gaza. Questo periodo ha segnato la fase di massima intensità nei flussi informativi, nella recente storia del conflitto, segnata anche da un rapidissimo spostamento del focus mediatico: dall'evento bellico iniziale alla crisi umanitaria culminata con l'incidente presso l'ospedale Al-Ahli, pertanto le motivazioni della scelta del periodo sono perché questo ci fornisce un caso di studio ideale per l'analisi della polarizzazione del framing e della velocità di propagazione delle notizie in contesti di crisi. Per ultimo per la crisi politico-istituzionale in Venezuela la finestra selezionata è dal 25 dicembre 2024 al 5 gennaio 2025 che analizza la fase culminante della crisi, con evento culmine l'intervento militare statunitense, l'Operazione Absolute Resolve. Definite le finestre a livello giornaliero e implementate direttamente poi nel codice come sequenze di date, sono state utilizzate per filtrare i file GDELT da dover scaricare. Il processo di acquisizione dei dati è stato effettuato a partire dalla repository ufficiale del progetto GDELT, utilizzando il *masterlist*, un file indice pubblico che elenca in modo esaustivo tutti i dataset che sono disponibili, specificando la dimensione, l'hash di controllo e URL di download. Il *masterlist* è stato scaricato localmente, poi successivamente partendo da questo indice creato, per ciascun evento e per ciascun giorno incluso nelle finestre temporali definite, sono stati selezionati i file GKG e Mentions corrispondenti a quella esatta data. Quindi per ciascun giorno è stato acquisito un solo file Translations GKG e Translations Mentions. Perché GDELT rende disponibili più snapshot al giorno disponibili con altissima frequenza, quindi ho scelto di limitare l'acquisizione a un singolo file per tipologia e giorno consentendo di mantenere un'unità temporale coerente con la mia analisi, per evitare anche sovrapposizioni informative tra più snapshot e possibili duplicazioni. Il download dei file è stato effettuato con un ciclo iterativo su ciascun evento e su ciascuna data nelle finestre. Poi per ogni file ho creato un controllo sull'effettiva acquisizione per escludere file vuoti e incompleti, se

il file non supera il controllo di qualità allora automaticamente scartato e non incluso nel dataset grezzo. I file validi poi sono stati salvati dentro la directory dedicata ai dati grezzi (raw), ho utilizzato una convenzione di denominazione (YYYYMMDDhhmmss) per associare ciascun file all'evento di riferimento e alla data di pubblicazione, facilitando così la tracciabilità e riproducibilità. La seconda fase del progetto è stata dedicata al processing dei dati GDELT acquisiti e alla costruzione di un dataset analitico che sia strutturato, per costituire la base per tutte le analisi successive. In questa fase ho avuto l'obiettivo di trasformare i file grezzi GKG e Mentions, caratterizzati da struttura complessa e semi-strutturata, in un insieme coerente con variabili che possano essere interpretate e aggregate a livello evento-giorno-dominio. In primo luogo ho definito le due directory di input e output, per distinguere i file grezzi da quelli processati (processed). Tutti gli output intermedi e finali di questa fase sono stati salvati in una directory dedicata, in modo da preservare integrità e riproducibilità. Poiché i file GDELT scaricati contengono la copertura informativa globale di ciascun giorno, ho reputato necessario associare ogni osservazione all'evento di studio di riferimento. Con questo evento (Ucraina, Gaza o Venezuela) è stato dedotto in base al nome del file origine, dato dalla convenzione spiegata prima. In questo modo ho potuto mantenere separati fin da subito i flussi informativi relativi ai diversi casi di studio già da subito nel preprocessing. Prima di procedere con estrarre le variabili rilevanti, ho condotto una verifica della struttura del file Translation GKG, caricando un file campione per identificare il numero di colonne e contenuti dei vari campi. La verifica ha confermato la presenza di 27 colonne, coerentemente con la documentazione ufficiale di GDELT. Poi ho voluto costruire un mapping delle colonne GKG, per associare a ciascun campo tecnico una descrizione esplicita (timestamp del documento, dominio della fonte, URL, temi, persone, organizzazioni, tono, segnali GCAM, metadati di pagina). Il mapping è stato poi salvato come file separato (gkg_column_map.csv) per documentare le scelte di preprocessing. Successivamente ho processato tutti i file GKG in maniera iterativa. Per ciascun file, i dati sono stati letti preservando l'originale struttura e rinominando le colonne uniformemente. Poi da ciascun file ho estratto esclusivamente le variabili rilevanti per l'analisi, includendo timestamp del documento, URL dell'articolo, dominio della fonte, temi associati all'articolo, persone e organizzazioni menzionate, tono lessicale aggregato, segnali semantici avanzati GCAM e metadati di pagina, da cui è stato estratto il titolo dell'articolo. Il timestamp è stato convertito in una variabile data a livello giornaliero, per mantenere la coerenza con l'unità temporale dell'analisi. Ho normalizzato il dominio della fonte estraendo il dominio principale dell'URL e convertendolo in lettere minuscole, per evitare duplicazioni per variazioni formali, esempio presenza o assenza "www". Il tono lessicale è stato convertito in formato numerico partendo dalla rappresentazione testuale originale, mentre invece per l'estrazione dei titoli degli articoli è stata effettuata partendo dai metadati di pagina, utilizzando un parsing basato su pattern testuali. In questa maniera ho potuto disporre di un'informazione testuale sintetica direttamente associata a ciascun documento e successivamente usata nelle analisi NLP. Poi ho verificato anche la copertura dei segnali GCAM, i quali erano disponibili per tutti i documenti analizzati, senza valori nulli, confermando così l'idoneità per l'utilizzo di tali misure per le analisi di framing semantico. In parallelo sono anche stati processati i file Translation Mentions, anche in questo caso letti iterativamente, e con l'estrazione di timestamp, URL dell'articolo e evento di riferimento. Una volta convertito timestamp in variabile data giornaliera e dominio normalizzato, a partire dai dati Mentions ho costruito un indicatore di attenzione mediatica aggregando il numero di citazioni a livello evento-giorno-dominio. Tale aggregazione consente di quantificare, per ciascuna fonte e in ciascun giorno, quante volte i contenuti pubblicati vengono ripresi o citati da altre fonti. Il numero delle menzioni al giorno rappresenta una misura quantitativa dell'intensità della copertura mediatica associata a ciascuna fonte, costituendo la base per l'analisi dell'attenzione nel tempo. L'ultima fase della fase di processing è consistita nell'integrare i dati GKG e Mentions in un unico panel analitico. L'unione dei due dataset è avvenuta usando come chiave comune l'evento, la data e il dominio della fonte. Consentendo quindi di associare, per ciascun

documento e per ciascuna fonte, le caratteristiche semantiche del contenuto informativo per una misura dell'attenzione mediatica generata. Per evitare problemi se ci sono domini presenti in GKG ma non nelle menzioni in un determinato giorno, allora in quel caso viene gestito con un numero di menzioni impostato a zero, evitando così di perdere osservazioni rilevanti. Il risultato finale di tutta questa fase è un panel evento–giorno–dominio che in contemporanea dice contenuto, tono, framing semantico e intensità della copertura mediatica. I dataset che ho creato e processato alla fine (*gdelt_gkg.csv*, *gdelt_mentions_daily.csv* e *gdelt_panel.csv*), insieme al file mapping delle colonne iniziale, sono stati tutti salvati nella directory per i dati processati e sono le basi per le analisi successive di attenzione mediatica, framing GCAM, NLP esplorativo e analisi di rete, contenute all'interno di questo progetto. In questa fase del progetto è stata condotta un'analisi esplorativa NLP basata esclusivamente sui titoli degli articoli giornalistici. Questa scelta che ho preso corrisponde a una precisa motivazione metodologica: il titolo non è altro che una sintesi condensata del contenuto informativo ed è il principale dispositivo con cui le redazioni selezionano, enfatizzano e incorniciano gli eventi. Perciò ho reputato che l'analizzare il linguaggio dei titoli consenta di osservare in modo diretto le strategie di tematizzazione e framing adottate nel contesto informativo globale, evitando, come vantaggio, la complessità e l'eterogeneità semantica dei testi completi degli articoli. Ho condotto l'analisi sul dataset GKG processato estraendo gli articoli dai metadati di pagina associati a ciascun documento, utilizzando come detto prima un parsing che contiene le info dell'HTML della pagina (PAGE_TITLE). Sono stati mantenuti per l'analisi esclusivamente i titoli che erano effettivamente presenti e non nulli, per garantire l'affidabilità delle analisi testuali successive. Questa procedura mi ha permesso di ottenere un corpus di quarantamila titoli validi, distribuiti sui tre eventi selezionati per lo studio. I titoli estratti sono stati normalizzati, per ridurre il rumore lessicale e rendere possibile comparare il testo tra fonti e contenuti diversi. In particolare li ho convertiti in minuscolo, rimosso entità HTML residue, caratteri non alfabetici e simboli di punteggiatura, e ho eliminato gli spazi multipli. Questa pulizia è volutamente stata fatta in maniera conservativa non applicando alcuna lemmatizzazione o stemming, per quanto l'obiettivo di questo progetto non è ricondurre le parole a forme canoniche, ma con questa analisi NLP osservare l'uso effettivo del lessico nei titoli così come appare nello spazio mediatico. I titoli normalizzati sono stati successivamente trasformati in un formato adatto all'analisi NLP tramite tokenizzazione, scomponendo il testo in singole parole (token). Per eliminare i termini poco informativi e puramente funzionali sono stati esclusi i token con lunghezza inferiore a 4 caratteri e le stopwords della lingua inglese. Il risultato che ho ottenuto è un corpus lessicale strutturato, dove ogni token ha un'associazione diretta all'evento di riferimento, alla data di pubblicazione e al dominio della fonte. Per individuare i termini più ricorrenti nei dati ho effettuato una prima analisi descrittiva calcolando le frequenze globali delle parole nei titoli. In questo modo ho osservato quali concetti dominano la copertura mediatica aggregata e non una misura di importanza semantica. A supportare poi l'interpretazione esplorativa ho generato dei wordcloud globali e specifici per ciascun evento, per esclusivamente visualizzare le sintesi, i pattern lessicali e le differenze macroscopiche tra le crisi, ma non ho interpretato nessuna di queste come misure quantitative rigorose e non hanno nessun valore inferenziale ai fini del progetto. Per approfondire le differenze linguistiche tra le crisi, ho deciso di condurre un'analisi basata sulla misura TF-IDF (Term Frequency–Inverse Document Frequency), calcolata a livello di evento. In questo contesto, ogni evento viene trattato come un “documento” aggregato e la TF-IDF viene utilizzata per identificare i termini che risultano relativamente più distintivi per una crisi rispetto alle altre. Questa analisi consente di visualizzare le specificità lessicali e tematizzazioni ricorrenti associate a ciascun evento, senza dover usare topic modelling, che non è coerente con la brevità dei titoli giornalistici. I segnali della TF-IDF sono stati interpretati come segnali di differenziazione linguistica, non come categorie di tematiche latenti. Nell'ultima parte di questa fase di analisi, ho integrato il corpus dei token insieme all'indicatore di attenzione mediatica derivato dal dataset Mentions. Per garantire compatibilità per

l'unione ho ricondotto a un formato standard le variabili temporali, questa integrazione è stata effettuata a livello evento–giorno–dominio, in modo tale da associare a ogni token il numero di menzioni giornaliere generate dalla fonte che ha pubblicato il titolo. Usando la distribuzione delle menzioni, ho classificato i giorni in tre categorie di attenzione (alta, media e bassa), utilizzando i quartili come soglie. Classificando il tutto così ho potuto confrontare il linguaggio dei titoli pubblicati in contesti di elevata visibilità mediatica con quelli in fasi di minore attenzione. In pratica mette in relazione la frequenza delle parole con il livello di attenzione mediatica, consentendo di osservare quali termini ricorrono più frequentemente nei giorni caratterizzati da una copertura intensa. In questa fase ho voluto analizzare l'attenzione mediatica associata a ciascuna crisi geopolitica, utilizzando il dataset Mentions di GDELT, non per valutare il contenuto informativo degli articoli ma con lo scopo di misurare l'intensità e l'evoluzione temporale della copertura mediatica, vista come volume totale di citazioni generate nello spazio informativo globale. Questa analisi parte dal dataset delle menzioni giornaliere preprocessate precedentemente (`gdelt_mentions_daily.csv`) dal file Translation Mentions. Qui ogni osservazione rappresenta il numero di menzioni associate a un certo dominio, in un certo giorno e per uno specifico evento di studio. Ho poi deciso di aggregare queste informazioni per ottenere una misura dall'attenzione mediatica complessiva. In primo luogo, ho aggregato le menzioni a livello evento-giorno, sommando il numero di citazioni, generate da tutte le fonti informative. Facendo così ho potuto poi costruire una serie temporale giornaliera dell'attenzione mediatica sul volume totale di copertura. L'aggregazione è stata fatta cercando di mantenere in modo più coerente possibile l'unità temporale delle analisi precedenti, per garantire la compatibilità tra gli eventi. Il dataset poi ottenuto è un risultato che rappresenta una misura diretta dell'intensità quotidiana della copertura mediatica, che ho poi utilizzato come base per due analisi descrittive principali. La prima analisi riguarda come evolve temporalmente l'attenzione mediatica, tracciando una serie temporale che mostra l'andamento giornaliero del numero totale di menzioni durante la finestra temporale selezionata. Ho scelto di costruire la visualizzazione in questione separatamente per ciascuna crisi, per evidenziare eventuali picchi, fasi di crescita o rapidi cali dell'attenzione, coerentemente con l'idea di shock informativi e dinamiche non lineari dell'agenda mediatica. Per quanto riguarda invece la seconda analisi, ho sintetizzato l'attenzione mediatica attraverso una misura di intensità media. In pratica per ciascun evento viene calcolato il numero medio di menzioni giornaliere, accompagnato anche dalla relativa deviazione standard. Questa misura mi ha permesso di confrontare le crisi in termini di livello medio di visibilità nello spazio informativo globale, fornendo così un indicatore comparativo della rilevanza mediatica complessiva. I valori medi sono stati visualizzati tramite un grafico a barre, che ho scelto di ordinare in modo decrescente, per confrontare meglio i diversi casi di studio. Anche in questo caso è importante sottolineare che le menzioni sono state interpretate solo come proxy quantitativi dell'attenzione mediatica, il dataset Mentions misura esclusivamente la circolazione e ripubblicazione delle notizie nell'ecosistema mediatico, riflettendo dinamiche di visibilità e amplificazione, rispetto alla ricezione individuale delle notizie. Queste due analisi nel complesso mi hanno fornito una base solida per collegare le analisi successive di framing semantico e NLP ai livelli di attenzione mediatica osservati nel tempo, interpretando i risultati testuali solamente con la luce della loro rilevanza nella risonanza informativa. In questa fase del progetto ho voluto condurre un'analisi del framing semantico della copertura giornalistica utilizzando le *Global Content Analysis Measures* (GCAM) integrate nel GKG di GDELT. L'obiettivo di questa analisi non è l'interpretazione del significato dei singoli articoli, né l'inferenza su stati emotivi o sulle intenzioni comunicative degli articoli, ma l'osservazione della dinamica temporale dei segnali semantici, valutando come la rilevanza di specifici attributi lessicali evolva nel contesto informativo globale durante le fasi iniziali di instabilità di geopolitica. Come già detto anche prima i segnali GCAM sono misure automatiche basate su pattern e dizionari lessicali, calcolati da GDELT attraverso le sue pipeline NLP multilingue. In questo lavoro ho scelto di interpretare tali segnali come proxy linguistici

aggregati, perché reputo possano essermi utili a descrivere le variazioni nel linguaggio mediatico nel tempo, non come indicatori psicologici o comportamentali. Questa analisi è stata condotta a partire dal dataset GKG preprocessato, mantenendo esclusivamente i documenti per cui il campo GCAM risultava disponibile e non nullo, per garantire una completezza delle informazioni. Ciascun documento contenente il campo GCAM, originariamente codificato a stringa che associa ogni codice GCAM a un valore numerico, è stato sottoposto a una fase di parsing per trasformare il tutto in un formato strutturato. Ho scelto questa operazione per poter ottenere una rappresentazione long dei dati GCAM, in cui ogni osservazione corrisponde a specifica coppia codice-valore, associata all'evento di riferimento, alla data di pubblicazione e al dominio della fonte. Una volta che ho ottenuto il dataset GCAM in formato long, ho aggregato in questo caso a livello evento-giorno-frame, calcolando per ciascun codice GCAM il valore medio giornaliero, per focalizzarmi meglio sulle dinamiche collettive del framing mediatico. Poiché i valori GCAM non direttamente confrontabili in termini assoluti, ciascun frame è stato normalizzato tramite z-score separatamente per ogni evento. Questa normalizzazione mi ha consentito di interpretare i valori come deviazioni relative rispetto al comportamento medio del frame dentro la specifica crisi, rendendo confrontabili le variazioni temporali e facilitando l'identificare i picchi, le inversioni o le fasi di stabilità del framing semantico. Per analizzare poi la relazione tra framing semantico e visibilità informativa, ho aggregato il dataset GCAM con la misura di attenzione mediatica derivata dal dataset precedente Mentions. In particolare ho aggregato le menzioni ulteriormente a livello evento-giorno, ottenendo una misura sintetica del volume complessivo della copertura mediatica quotidiana. L'integrazione è stata effettuata con l'uso di evento e data come chiavi comuni, associando così ciascuna osservazione GCAM al corrispondente livello di attenzione mediatica. Anche qui l'attenzione poi è stata interpretata come proxy quantitativo della visibilità delle notizie nel contesto informativo globale. Siccome i segnali GCAM avevano un'elevata dimensionalità, ho scelto di concentrare l'analisi su un sottoinsieme di frame selezionati in base alla loro variabilità temporale. Per ciascun evento ho calcolato la deviazione standard dei valori normalizzati (z-score) di ciascun frame, e poi ho selezionato quelli caratterizzati da maggiore variabilità nel tempo. Procedendo in questo modo ho potuto focalizzarmi sulle dimensioni semantiche che mostrano effettive dinamiche temporali durante le fasi della crisi, evitando così frame stabili e poco informativi dal punto di vista dell'evoluzione del discorso mediatico. I frame GCAM che ho selezionato sono poi stati analizzati con delle visualizzazioni temporali per mostrare l'andamento dei segnali normalizzati nel tempo, insieme anche all'andamento dell'attenzione mediatica, che ho riportato in scala normalizzata. Questa analisi mi ha permesso di osservare le eventuali co-variazioni tra framing semantico e intensità della copertura, senza formulare nessuna ipotesi di causalità o dipendenza diretta. Questa analisi ha avuto un obiettivo descrittivo ed esplorativo per identificare i pattern temporali e le relazioni osservabili nello spazio informativo, non stimare cause o costruire modelli predittivi. I risultati sono poi stati interpretati come segnali per comprendere la riorganizzazione del linguaggio mediatico durante shock informativi e come queste riorganizzazione si collocano rispetto ai livelli di attenzione osservati in precedenza. Una volta caratterizzata l'evoluzione temporale dei frame semantici GCAM per ciascun evento di studio, la mia attenzione metodologica si è spostata sull'esplorazione della relazione temporale tra framing semantico e attenzione mediatica. Non per introdurre nuove misure del contenuto, ma per mettere in relazione i segnali semantici già analizzati con la visibilità informativa osservata. Questa seconda analisi si è basata sul dataset `gcam_framing_daily.csv`, che integrava per ciascun evento e giorno i valori medi normalizzati (z-score) dei frame GCAM con il numero totale di menzioni giornaliere. Per rendere l'analisi in questione più interpretabile mi sono focalizzato solo sui segnali più rilevanti, scegliendo un limitato numero di frame GCAM, in particolare prima li ho ordinati per l'intensità media assoluta del loro z-score nel periodo considerato, poi ho mantenuto solo quelli con maggiore variabilità semantica complessiva. Ho scelto quindi di concentrare l'attenzione sui frame che mostravano le


dinamiche temporali più marcate, evitando di aggiungere segnali stabili o marginali. I valori selezionati sono poi stati aggregati a livello evento-giorno e messi in relazione con l'attenzione mediatica normalizzata. Il numero di menzione è stato trasformato su una scala comune, per poter confrontare gli andamenti temporali con ordini di grandezza diversi. Il risultato di tutto questo è stata una rappresentazione dell'evoluzione temporale dei frame semantici GCAM e dell'attenzione mediatica, visualizzata con serie temporale per ciascuno degli eventi di studio, mentre ho creato anche sui grafici una linea tratteggiata che indica l'andamento normalizzato dell'attenzione mediatica. Con l'obiettivo finale di vedere come le variazioni di linguaggio mediatico si sviluppino in concomitanza con fasi di maggiore o minore visibilità informativa. Dopo aver analizzato l'attenzione mediatica e il framing semantico a livello aggregato tramite GDELT, il progetto in questione prevede una fase di approfondimento testuale su un campione selezionato di articoli. L'obiettivo di questa fase non è quella di estendere l'analisi a tutti i contenuti testuali che abbiamo disponibili nel nostro dataset, ma di ottenere un campione controllato di articoli che siano ad alta visibilità, perché ho reputato che questo possa essere utile al fine di validare qualitativamente e descrittivamente dei pattern osservati nelle analisi precedenti. La selezione del campione degli articoli è stata fatta a partire dal panel analitico evento-giorno-dominio (`gdel_panel.csv`), il quale integra sia contenuti informativi che attenzione mediatica. Come prima cosa ho eliminato record privi di URL valido o duplicati, per garantire l'unicità delle fonti e l'accessibilità contenuti. Poi per ciascun evento studio, ho selezionato i 50 articoli con il più alto numero di menzioni, utilizzando il numero di citazioni come criterio rilevante. In questo modo ho focalizzato l'analisi su contenuti che hanno avuto maggiore risonanza nello spazio mediatico globale, evitando di selezionare casualmente gli articoli. A ciascun articolo selezionato è stata poi associata una variabile per documentare il criterio di selezione ("`top_mentions_by_event`"). Il dataset risultante (`articles_to_scrape.csv`) contiene soltanto le informazioni necessarie per lo scraping e rappresenta il sottoinsieme mirato del corpus. La fase di scraping è stata volutamente creata per estrarre soltanto una porzione limitata e comparabile del contesto testuale degli articoli selezionati, evitando di estrarre l'intero corpus degli articoli. Per ciascun URL selezionato è stata effettuata una richiesta HTTP con verifica dello stato della risposta e con l'utilizzo di un *user-agent* dichiarato per finalità accademiche. In presenza di errori HTTP, timeout e contenuti non accessibili, l'articolo è stato automaticamente marcato con uno stato e escluso dalle fasi successive dall'analisi, mentre per gli articoli direttamente accessibili sono stati estratti due elementi principali: il titolo HTML della pagina e una parte di testo iniziale dell'articolo. In particolare sono stati selezionati esclusivamente paragrafi con una lunghezza minima predefinita, per escludere i contenuti marginali o non informativi. Il testo finale che è stato poi associato all'articolo è costituito unendo i primi tre paragrafi validi così da poter catturare l'introduzione narrativa e informativa dell'articolo, provando a mantenere un livello di comparabilità tra fonti diverse. Il processo di scraping include inoltre un controllo di qualità sul contenuto estratto, per escludere gli articoli con testo insufficiente o non valido. L'output ottenuto da questa fase è poi un dataset strutturato (`scraped_articles.csv`) che documenta, per ogni articolo presente, lo stato dello scraping e il contenuto testuale effettivamente estratto e disponibili per l'analisi. Gli articoli quindi risultati correttamente scrapeati sono poi stati sottoposti a una fase di preprocessing testuale distinta, rispetto a quella applicata in precedenza ai titoli. In questa fase ho mantenuto esclusivamente gli articoli con stato di scraping valido e con contenuto testuale effettivamente disponibili ed usabile. Il testo è stato normalizzato con una conversione in minuscolo, la rimozione delle entità HTML che potevano ancora essere presenti, l'eliminazione di caratteri non alfabetici oppure in simboli, e la riduzione degli spazi multipli. Non sono poi state applicate tecniche di stemming o lemmatizzazione, in quanto l'obiettivo non è l'analisi linguistica profonda, ma costruire un corpus coerente e confrontabile per analisi descrittive. Il testo normalizzato è stato poi tokenizzato, prendendo e trattando ciascuna parola come un'unità lessicale di base. Ho rimosso le stopwords della lingua inglese e ho filtrato i token di lunghezza inferiore a quattro caratteri, per

ridurre il possibile rumore sintattico. Le operazioni di tokenizzazione e gestione del corpus sono state implementate utilizzando il pacchetto `tinytext`, mentre le fasi di filtraggio, aggregazione e normalizzazione delle frequenze sono state gestite tramite `dplyr`. Il risultato di questo processo è stato un dataset strutturato di token (`text_tokens.csv`) che è il corpus testuale degli articoli con un'elevata attenzione mediatica. Dopo aver costruito il corpus dei token testuali, è stato effettuato un confronto per scopo esplorativo tra il linguaggio dei titoli e quello del contenuto degli articoli. A tal fine, ho poi confrontato le frequenze dei token estratte dai testi con le frequenze globali dei token dei titoli, precedentemente calcolate. Per rendere confrontabili i due insiemi, ho normalizzato le frequenze in termini relativi all'interno di ciascuna fonte (titoli vs contenuto testuale). Questo confronto permette di osservare le diverse differenze e sovrapposizioni nel lessico utilizzato nei titoli rispetto a quello impiegato nel corpo degli articoli, senza formulare inferenze causali o interpretazioni semantiche profonde. I risultati di questa fase sono stati salvati in un dataset dedicato (`title_vs_text_top_words.csv`), che contiene le parole più rappresentative per ciascuna fonte. Per completare l'analisi esplorativa ho generato una wordcloud dei token del testo scrapedo, con scopo puramente descrittivo e illustrativo per fare una sintesi del lessico dominante degli articoli campionati. In finale, questa fase serve per dare una spiegazione concreta ai numeri emersi dall'analisi, è un approfondimento dei nostri dati e del metodo statistico usato. A integrare le analisi temporali e semantiche condotte sui dati GDELT, ho scelto di includere un'analisi di rete finalizzata a esplorare la struttura relazionale della copertura mediatica globale. In particolare l'obiettivo finale di questa fase è la ricostruzione e l'analisi di una rete di co-copertura tra domini informativi, per individuare pattern di centralità, concentrazione e intermediazione nel contesto informativo internazionale durante le crisi selezionate. La rete è stata costruita partendo dal panel analitico evento-giorno-dominio (`gdelt_panel.csv`). L'unità di analisi relazionale è costituita dalla co-occorrenza di due domini informativi nella copertura dello stesso evento nello stesso giorno. Per ciascuna coppia (evento, data) vengono identificati i domini unici con almeno un contenuto pubblicato, e poi da questi vengono generati tutte le possibili coppie dominio-dominio. Ciascuna coppia dominio-dominio rappresenta un arco non diretto, perché la relazione di co-copertura non implica nessuna direzionalità, influenza o citazione reciproca, ma soltanto una condivisione temporale della copertura informativa. I nodi della rete corrispondono quindi ai domini delle fonti giornalistiche, mentre gli archi sono le relazioni di co-presenza nello stesso contesto informativo giornaliero. L'unità temporale della costruzione della rete è dunque evento-giorno, per garantire coerenza con le analisi precedenti di attenzione mediatica e framing semantico. Le relazioni dominio-dominio che ho generato a livello evento-giorno sono poi state successivamente aggregate sull'intero periodo di osservazione. Il peso di ciascun arco è stato definito come il numero di giorni in cui la stessa coppia di domini ha co-coperto il medesimo evento. Tale peso rappresenta una misura di persistenza e intensità della relazione informativa, distinguendo i legami strutturali ricorrenti dalle co-occorrenze sporadiche. Per continuare poi a scopo di ridurre il rumore informativo e per limitare l'analisi a relazioni strutturali rilevanti è stato applicato sugli archi un filtro di robustezza, così da poter mantenere soltanto le coppie di domini con almeno cinque co-occorrenze nel periodo che ho scelto di analizzare. Questa soglia mi ha permesso di escludere le relazioni episodiche o accidentali, cercando di focalizzare l'attenzione esclusivamente sulle connessioni più stabili e sistematiche nel contesto informativo. La rete risultante da risultante ho scelto di modellarla come una rete non diretta e pesata, dove i nodi sono domini informativi, gli archi rappresentano delle relazioni di co-copertura e i pesi degli archi riflettono la frequenza di tali relazioni. Non viene introdotta nessuna ipotesi di causalità, influenza editoriale o direzione del flusso informativo. Sulla rete poi filtrato ho calcolato tre metriche di centralità, usando il pacchetto `igraph`, tra cui: la *degree centrality*, ovvero il numero di connessioni di ciascun dominio che rappresenta anche il livello di integrazione della fonte nel flusso informativo globale, la *betweenness centrality*, calcolata in forma normalizzata, che cerca di catturare il ruolo di intermediazione strutturale di un dominio nel

connettere le diverse parti della rete costruita, e come terza metrica la eigenvector centrality, che misura la centralità di un nodo rispetto alla centralità dei suoi vicini, identificando così i domini inseriti nei nuclei informativi più influenti. Queste metriche sono state interpretate in senso strutturale, come proprietà della topologia della rete, non come indicatori di qualità o orientamento editoriale dei contenuti. Ai fini della visualizzazione grafica della rete ho ritenuto opportuno, trasformare i pesi degli archi con una funzione $\log(1+w)$. Grazie a questa normalizzazione logaritmica ho potuto ridurre la forte asimmetria nella distribuzione delle co-occorrenze, evitando che poche relazioni ad altissimo peso dominassero esclusivamente la visualizzazione della rappresentazione, questo mi ha permesso di migliorare la leggibilità della struttura reticolare. La disposizione dei nodi nello spazio è stata fatta scegliendo un layout force-directed di tipo Fruchterman-Reingold, pesato sui valori normalizzati degli archi. Il layout è stato calcolato con molte iterazioni, per favorire la stabilizzazione della configurazione e limitare fenomeni di collasso visivo. Le visualizzazioni finali prodotte hanno una funzione esplorativa e descrittiva. Per indagare più a fondo la struttura della rete centrale, ho deciso di isolare un sottografo composto dalla top 20 dei domini con il grado più elevato. Questo sottografo rappresenta il core della rete di attenzione mediatica, ovvero tutte le fonti più interconnesse in termini di co-copertura. L'analisi successiva poi del core ha consentito di evidenziare i nodi dominanti nello spazio informativo globale e di osservare la densità delle relazioni tra le principali fonti. In conclusione l'analisi di rete non ha l'obiettivo di spiegare il contenuto delle informazioni interne degli articoli, né di modellare ipotetici processi di diffusione causale delle notizie tra i vari attori. Essa costituisce uno strumento descrittivo e strutturale, per integrare l'analisi di attenzione mediatica e framing semantico, con lo scopo di fornire anche una rappresentazione della configurazione relazionale dell'ecosistema mediatico durante le crisi geopolitiche analizzate.

RISULTATI

Dai risultati dell'analisi temporale dell'attenzione mediatica, che ho misurato usando il numero giornaliero di menzioni nei media globali, vengono evidenziati gli andamenti distinti nelle fasi iniziali delle tre crisi geopolitiche analizzate nel progetto: guerra in Ucraina, escalation del conflitto a Gaza e crisi politico-istituzionale in Venezuela.




L'andamento dell'attenzione mediatica associata alla guerra in Ucraina mostra una dinamica concentratissima nelle primissime giornate successive all'invasione russa, con il picco estremo pronunciato nella data tra il 24 e 25 febbraio, queste giornate sono state caratterizzate dall'avvio dell'attacco militare su vasta scala, dai bombardamenti nella capitale Kiev e altre principali città


ucraine ed anche dalla occupazione dell'area di Chernobyl, dal grafico è possibile notare come la copertura mediatica globale è massima. Questo andamento è coerente con la configurazione di uno shock informativo improvviso, tipo degli eventi geopolitici ad alta intensità. I giorni successivi sono segnati dalle prime sanzioni verso la Russia da parte dell'Unione Europea e Stati Uniti infatti la copertura inizia a frammentarsi per via dei molteplici sviluppi da parte del conflitto. Il 26 e 27 febbraio l'attenzione inizia a calare in relazione a eventi di natura prevalente economica e strategica, l'esclusione dal sistema SWIFT per gli istituti bancari russi, l'autorizzazione di invio di armi da parte di Germania e l'annuncio dell'allerta nucleare per le forze russe introducono nuove dimensioni interpretative nella copertura mediatica, dove assistiamo ad una ristrutturazione del discorso informativo globale, c'è un calo netto che rappresenta la fine della saturazione iniziale, l'evento dell'invasione non è più l'unico tema dominante. Dal 28 febbraio al 5 marzo non vediamo più il picco iniziale, ma l'attenzione tuttavia diciamo che non collassa, abbiamo anzi delle oscillazioni modeste con risalite, piccoli cali e livelli abbastanza stabili, questo pattern è perché non abbiamo un singolo evento dominante ma più eventi rilevanti distribuiti nel tempo come l'emergere di temi legati alle conseguenze umanitarie del conflitto, i rischi sistemici della guerra e gli sviluppi politico-diplomatici, la caduta di Kherson, i dibattiti internazionali in sede ONU e le preoccupazioni sulla sicurezza nucleare. L'attenzione mediatica associata alla crisi di Gaza mostra una dinamica più progressiva e meno concentrata rispetto al caso ucraino, il grafico mostra una crescita graduale delle menzioni nei giorni successivi al 7 ottobre, fino a raggiungere il massimo valore tra l'11 e il 12 ottobre, questo andamento suggerisce che la saturazione dell'agenda mediatica non è immediata, ma è costruita nel tempo con l'accumularsi di sviluppi militari, politici e umanitari. Nella fase finale del periodo analizzato si registra una nuova risalita dell'attenzione, coerentemente con l'emergere di eventi ad alto impatto simbolico e umanitario, in particolare l'esplosione presso l'ospedale Al-Ahli il 17 ottobre. Nel complesso l'attenzione mediatica della crisi di Gaza nel periodo selezionato si configura come un caso intenso di attenzione mediatica, costruito in modo incrementale con più momenti di riattivazione piuttosto che uno shock iniziale. L'attenzione mediatica alla crisi venezuelana invece presenta un'intensità relativamente inferiore rispetto ai due altri casi di conflitto armato, il grafico mostra livelli di copertura più contenuti e variabilità moderata, senza la presenza di uno shock informativo improvviso. L'attenzione anche in questo caso cresce in modo frammentato e graduale, coerente con la natura della crisi prevalentemente politico-istituzionale. Il picco massimo della finestra temporale riguarda il 3 gennaio 2025 che coincide con una forte pressione diplomatica internazionale, dove diversi attori internazionali e l'Unione europea mettono in discussione l'effettiva legittimità del governo in vista dell'insediamento presidenziale. Successivamente l'attenzione tende a ridursi, e nel complesso la crisi venezuela è più un caso di attenzione mediatica sostenuta ma non esplosiva.

Intensidad media de la atención mediática por crisis

Promedio diario de menciones en medios globales (GDELT)




A integrazione dell'analisi temporale, è stata calcolata anche l'intensità media dell'attenzione mediatica per ciascuna crisi, misurata come il numero medio giornaliero di menzioni nel periodo preso in caso nel progetto. I risultati fanno vedere come la Guerra in Ucraina presenta il livello di attenzione più elevato tra i tre casi analizzati. La crisi di Gaza segue con un valore medio di pochissimo inferiore e per ultimo la crisi in Venezuela che registra un livello di attenzione sensibilmente più basso in confronto agli altri due eventi. Questo confronto ci permette di vedere come le crisi possono differire non solo nella forma temporale della copertura, ma anche nella quantità di spazio informativo occupato nei media nelle fasi iniziali. I risultati preliminari indicano una risposta differenziata dell'attenzione mediatica globale agli eventi critici. La portata volumetrica è massima e immediata per i conflitti bellici ad alta intensità, mentre è più modesta per le dinamiche politico-istituzionali. Tale diversità costituisce il punto di partenza per le analisi successive, fornendo il contesto semantico e reticolare necessario a interpretare le dinamiche linguistiche osservate alla luce dei diversi livelli di visibilità iniziali.



Dai risultati dell'analisi del framing semantico, con l'uso dei segnali GCAM, (es. c15.99, c9.73) codici di riferimento dei dizionari lessicali standard utilizzati in NLP (NRC Emotion Lexicon, Harvard IV-4, WordNet, VADER), utilizzati in questo lavoro esclusivamente come proxy linguistici aggregati per osservare la variazione temporale relativa del linguaggio durante le fasi iniziali delle tre crisi. I risultati mostrano per quanto riguarda l'Ucraina una fortissima volatilità semantica nelle primissime giornate successive all'invasione, con il picco iniziale dell'attenzione mediatica. Le oscillazioni sono molto ampie e soprattutto non sincronizzate, indicando una fase di ristrutturazione rapida del discorso informativo. Nei giorni successivi, come detto anche prima, la variabilità dei frame si riduce e gli andamenti sono coerenti con il consolidamento del framing dopo la fase di shock iniziale. Per quanto riguarda invece il conflitto a Gaza, l'analisi del framing semantico mostra una situazione diversa rispetto al caso ucraino, i segnali GCAM evidenziano una dinamica altamente frammentata, anche qui caratterizzato dalla coesistenza di più frame con andamenti abbastanza divergenti. I segnali semantici in questione non convergono troppo verso una singola cornice dominante, suggerendo una certa pluralità di cornici interpretative che nel tempo sono riorganizzate in maniera non lineare coerente con la complessità di un contesto di notizie associato alla crisi. Nella crisi Venezuela invece i frame GCAM mostrano una configurazione diversa rispetto ai conflitti armati precedenti. L'attenzione mediatica è più contenuta e stabile relativamente nel tempo considerato. I

segnali mostrano variazioni semantiche puntuali, con picco intorno al finire di dicembre, seguito poi da un rapido ritorno ai livelli medi. Nel suo complesso questo framing appare caratterizzato da una stabilità relativa, coerente con coperture istituzionali e diplomatiche, piuttosto che escalation improvvisa. A supporto dei risultati dell'analisi descritta la figura seguente mostra come evolvono nel tempo i principali frame GCAM selezionati, considerandoli senza in questo caso l'andamento dell'attenzione mediatica.

Evolución temporal de los principales frames GCAM




Continuando poi abbiamo i risultati dell'analisi testuale esplorativa condotta sul sottoinsieme selezionato di articoli con un'elevata attenzione mediatica, in particolare quelli con il maggior numero di menzioni per ciascun evento in modo tale da approfondire qualitativamente il linguaggio utilizzato nello spazio informativo globale. A seguito delle procedure di scraping e dei controlli di qualità, il campione finale analizzato è risultato composto da 91 articoli con testo valido, distribuiti solo sui casi di Gaza e Venezuela, mentre per la guerra in Ucraina non è stato possibile ottenere un numero di contenuti testuali utilizzabili, in particolare nel nostro campione selezionato, questo ha limitato l'analisi ai solo due eventi. Il corpus risultante comparabile e coerente, è composto da 4000 token distinti, che rappresentano il lessico effettivo dei paragrafi degli articoli ad alta visibilità. L'analisi delle frequenze ha mostrato una forte concentrazione su termini direttamente legati al contesto geopolitico e istituzionale degli eventi analizzati. Nel caso di Gaza emergono riferimenti a Israele, Hamas e elementi di sicurezza e ordine pubblico, mentre nel caso venezuelano ricorrono molto frequentemente termini riguardanti le istituzioni, il governo e la dimensione politico-amministrativa. Ho ritenuto questa distribuzione lessicale risultante coerente con la natura dei due contesti presi in analisi e con le dinamiche di copertura osservate nelle analisi precedenti. L'ulteriore analisi di linguaggio utilizzato nei titoli degli articoli, estratti dai metadati di GDELT, e quello impiegato nel corpus del testo degli articoli scrapeati, ha mostrato una sostanziale coerenza tra i due livelli. Il confronto delle due distribuzioni relative delle parole ha suggerito che le parole più rappresentative nei titoli tendono a ricorrere anche nei testi degli articoli, dimostrando che i titoli funzionano come sintesi fedele dei temi effettivamente poi sviluppati nei contenuti. In questa analisi esplorativa non sono emersi segnali evidenti di disallineamento tra headline e testo, né differenze lessicali da identificare forti divergenze tra framing sintetico e narrazione estesa. Per supportare i risultati a livello descrittivo ho prodotto anche una visualizzazione tramite wordcloud, usata solo con finalità illustrativa per sintetizzare nella maniera più breve il lessico dominante negli articoli con maggiore attenzione, anche in questo caso la visualizzazione evidenzia una forte concentrazione attorno a termini attribuibili al contesto geopolitico e istituzionale (*israel, hamas, gaza, israeli, police, department, court, officials*) degli eventi analizzati, con chiara centralità di attori, luoghi, temporalità

giornalistiche e riferimenti legati principalmente alla sicurezza e all'ordine pubblico (*monday, tuesday, friday, weekend, news, report, video*). La presenza di termini temporali e giornalistici probabilmente riflette le convenzioni tipiche della cronaca e della copertura news-oriented. Nel complesso, anche il wordcloud ha confermato, in modo visivo, la coerenza del linguaggio utilizzato degli articoli con alta visibilità, che abbiamo usato, con i pattern semantici emersi dalle analisi quantitative precedentemente.



A integrazione dei risultati delle analisi temporali dell'attenzione mediatica e del framing semantico, abbiamo i risultati dell'analisi di rete, con obiettivo di esplorare la struttura relazionale della copertura mediatica globale durante le tre crisi geopolitiche analizzate. La rete risultante è composta da 410 domini informativi e circa 5000 relazioni strutturali, configurandosi come una rete non diretta e pesata, caratterizzata da una struttura densa e concentrata. L'analisi delle metriche di centralità evidenzia una forte concentrazione della rete attorno a un numero limitato di nodi centrali. In particolare i domini come *yahoo.com*, *news.yahoo.com*, *aol.com* e *dailymail.co.uk* emergono come primi in principalmente tutte e tre le metriche considerate: degree centrality, betweenness centrality ed eigenvector centrality. La ricorrenza di questi domini suggerisce l'esistenza di un core informativo stabile che occupa la posizione centrale nella struttura dell'ecosistema mediatico globale preso in studio.

**Red de Atención Mediática entre Dominios
(Estructura global, enlaces fuertes)**




Interpretativamente, la degree centrality ci indica come tali domini siano fortemente integrati nel flusso informativo complessivo, condividendo la copertura degli eventi con un ampio numero di altre fonti. La betweenness centrality, per i domini in cui è elevata, segnala invece il ruolo di intermediazione strutturale suggerendo come tali domini connettono porzioni diverse della rete e facilitano la circolazione sincronizzata dell'attenzione mediatica. Infine, i valori elevati di eigenvector centrality indicano che per alcuni domini oltre ad essere anche molto connessi, risultano anche collegati ad altri nodi molto centrali, rafforzando la posizione nel nucleo della rete. La visualizzazione di sopra mostra chiaramente una struttura riconducibile ad un modello core-periphery. Al centro della rete gruppo ristretto di domini molto connessi tra loro e anche numerose testate nazionali oppure locali che si dispongono in posizione periferica, ma con forte legame con il nucleo centrale. Questa visualizzazione suggerisce una dipende forte tra media globali e locali, dove le fonti periferiche si sincronizzano con un insieme di hub informativi centrali.


rank	domain	degree	betweenness	eigenvector	top_metric
1	dailymail.co.uk	337	0.19204807	0.9775614	Betweenness
2	yahoo.com	335	0.14879496	1.0000000	Betweenness
3	aol.com	249	0.08134604	0.8426431	Betweenness
4	news.yahoo.com	260	0.06381321	0.8861484	Betweenness
5	cbc.ca	194	0.04165261	0.7173185	Betweenness
1	dailymail.co.uk	337	0.19204807	0.9775614	Degree
2	yahoo.com	335	0.14879496	1.0000000	Degree
3	news.yahoo.com	260	0.06381321	0.8861484	Degree
4	aol.com	249	0.08134604	0.8426431	Degree
5	cbc.ca	194	0.04165261	0.7173185	Degree
1	yahoo.com	335	0.14879496	1.0000000	Eigenvector
2	dailymail.co.uk	337	0.19204807	0.9775614	Eigenvector
3	news.yahoo.com	260	0.06381321	0.8861484	Eigenvector
4	aol.com	249	0.08134604	0.8426431	Eigenvector
5	cbc.ca	194	0.04165261	0.7173185	Eigenvector

L'analisi successiva del sottografo composto dai 20 domini con il grado più elevato rafforza ulteriormente l'evidenza emersa dall'analisi della rete globale, mette ancora di più in luce un core informativo compatto e densamente interconnesso, che è il nucleo strutturale dell'ecosistema mediatico osservato. Dentro questo sottografo i domini centrali sono collegati in maniera molto forte tra loro, indicando anche una elevata co-presenza nella copertura delle crisi geopolitiche analizzate. La struttura del core tende a organizzarsi attorno a un insieme di hub informativi globali, costituito principalmente da media generalisti con ampia diffusione e piattaforme aggregatrici. Questi domini sono essenziali per raccordare le informazioni a livello nazionale e locale, garantendo che la copertura sia uniforme e coerente tra le diverse aree geografiche.

**Top 20 Dominios más Centrales
(Core de Atención Mediática)**



Red de Atención Mediática entre Dominios



CONCLUSIONI

Questo progetto ha analizzato la copertura mediatica globale di tre crisi geopolitiche, usando un approccio integrato e ibrido, basato su dati strutturati derivanti da contenuti in origine non strutturati (GDELT), ed anche dati testuali non strutturati ottenuti tramite lo scraping mirato degli articoli con

alta visibilità. Unendo l'analisi temporale dell'attenzione mediatica, framing semantico attraverso GCAM, analisi testuale esplorativa e analisi di rete, il lavoro ha provato a fornire una lettura a più livelli delle dinamiche informative nelle fasi iniziali delle crisi. I risultati hanno mostrato che l'attenzione mediatica globale risponde in modo diverso a seconda della natura dell'evento. La guerra in Ucraina, ad esempio, rappresenta uno shock informativo improvviso con un'altissima intensità, seguito poi da una rapida saturazione dell'agenda mediatica e da una riorganizzazione del discorso informativo dopo i primi tre giorni principali. Il conflitto a Gaza invece presenta delle dinamiche più incrementali, con momenti di riattivazione dell'attenzione e più frammentazione temporale e semantica. Per ultimo invece la crisi venezuelana, evidenzia livelli di attenzione contenuti e stabili, coerenti con una copertura che vede prevalentemente una crisi istituzionale e diplomatica. L'analisi di framing conferma queste differenze descritte, perché ci mostra una forte volatilità iniziale del frame nel caso ucraino, una pluralità di interpretazioni invece nel caso di Gaza e una relativa stabilità nel caso della crisi venezuelana. Questo suggerisce che le dinamiche linguistiche evolvono insieme all'intensità dell'attenzione mediatica, ma riflettono anche come il modo di fare informazione cambi e si ristrutturano a seconda del tipo di emergenza affrontata. L'analisi testuale esplorativa, condotta sul sottoinsieme, ha un valore principalmente descrittivo e di supporto alle analisi quantitative precedenti di questo progetto. Infine l'analisi di rete ha evidenziato come la copertura mediatica globale delle crisi geopolitiche ruoti attorno a una struttura di tipo centro-periferia, con nucleo ristretto da domini fortemente centrali che hanno un ruolo chiave nel coordinare e sincronizzare l'attenzione informativa internazionale. Questa struttura aiuta a capire come l'attenzione del pubblico e il modo di presentare le notizie sono legati tra loro. Tutto questo avviene in un sistema dell'informazione dove le fonti sono strettamente connesse e dipendono da pochi centri principali. Il lavoro in questione presenta alcuni limiti che ritengono opportuni chiarire, in primo luogo l'analisi si concentra soltanto sulle fasi iniziali delle crisi selezionate in questione, limitando quindi l'osservazione di dinamiche di lungo periodo, come l'attuale continuo ed evolversi della guerra in Ucraina e del conflitto a Gaza, e limitando anche i processi di normalizzazione della copertura mediatica. In secondo luogo i segnali GCAM, essendo basati su dizionari lessicali standardizzati, rappresentano solo una proxy linguistica aggregata che non consente di cogliere tutte le sfumature contestuali o le interpretazioni discorsive più profonde dell'analisi testuale. L'analisi testuale condotta poi è basata solamente sul sottoinsieme ridotto di articoli ad alta visibilità e solo per due dei tre eventi considerati, per problemi e vincoli di disponibilità nello scraping. Infine l'analisi di rete è stata interpretata in termini strutturali, senza introdurre ipotesi sull'influenza tra i vari editori, sulla diffusione casuale o sulle dinamiche di agenda-setting. Sebbene questa scelta sia coerente con gli obiettivi di questo progetto, limita la possibilità di trarre conclusioni sui meccanismi dell'informazione tra media.

Referenze

Leetaru, K., & Schrod, P. A. (2013). GDELT: Global data on events, location, and tone. Paper presented at the ISA Annual Convention. Página web. <https://www.gdelproject.org/>
I dati utilizzati provengono dal Global Knowledge Graph (GKG) e dal dataset Mentions del progetto GDELT.

GDELT Project. (2019). GDELT Global Knowledge Graph Codebook Version 2.1 [Documento técnico]. GDELT Project.
http://data.gdelproject.org/documentation/GDELT-Global_Knowledge_Graph_Codebook-V2.1.pdf

McCombs, M. E., & Shaw, D. L. (1972). The agenda-setting function of mass media. *Public Opinion Quarterly*, 36(2), 176–187. <https://doi.org/10.1086/267990>

Baumgartner, F. R., & Jones, B. D. (1993). *Agendas and instability in American politics*. University of Chicago Press.

Cavari, A., & Efrat, A. (2025). Polarized public agenda in times of crisis. *Journal of European Public Policy*. <https://doi.org/10.1080/13501763.2025.2552418>

Entman, R. M. (1993). Framing: Toward clarification of a fractured paradigm. *Journal of Communication*, 43(4), 51–58. <https://doi.org/10.1111/j.1460-2466.1993.tb01304.x>